



# VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ

BRNO UNIVERSITY OF TECHNOLOGY

**CENTRUM SPORTOVNÍCH AKTIVIT**

CENTRE OF SPORTS ACTIVITIES

**ODHAD TEPOVÉ FREKVENCE ZE SIGNÁLŮ PPG**

HEART RATE ESTIMATION FROM THE PPG SIGNALS

**BAKALÁŘSKÁ PRÁCE**

BACHELOR'S THESIS

**AUTOR PRÁCE**

AUTHOR

Petr Šimčák

**VEDOUCÍ PRÁCE**

SUPERVISOR

doc. Ing. Jiří Kozumplík, CSc.

**BRNO 2025**



# Bakalářská práce

bakalářský studijní program **Sportovní technologie**

Centrum sportovních aktivit

**Student:** Petr Šimčák

**ID:** 226320

**Ročník:** 3

**Akademický rok:** 2024/25

## NÁZEV TÉMATU:

### Odhad tepové frekvence ze signálů PPG

#### POKYNY PRO VYPRACOVÁNÍ:

- 1) Vypracujte stručný přehled metod odhadu tepové frekvence (TF) z fotopletysmogramů (signálů PPG). 2) Navrhněte, realizujte a popište algoritmy pro detekci systolických maxim v signálech PPG. Algoritmy detekce a určení TF ověřte na databázi CapnoBase. 3) Dále ověřte algoritmy na databázi Brno University of Technology Smartphone PPG Database (BUT PPG). 4) Navrhněte automatické posouzení kvality testovaných signálů. 5) Získané výsledky vyhodnotěte a vypracujte studii shrnující výsledky práce.

#### DOPORUČENÁ LITERATURA:

- [1] VADREHU S., MANIKANDAN M.S.: Use of Zero-Frequency Resonator for Automatically Detecting Systolic Peaks of Photoplethysmogram Signal. Healthcare Technology Letters, 2019, Vol. 6, Iss. 3, pp. 53–58.
- [2] PARK J., SEOK H.S., KIM S.-S., SHIN H.: Photoplethysmogram Analysis and Applications: An Integrative Review. Front. Physiol., 2022, 12:808451. pp. 1-23.

**Termín zadání:** 5.2.2025

**Termín odevzdání:** 31.5.2025

**Vedoucí práce:** doc. Ing. Jiří Kozumplík, CSc.

předseda rady studijního programu

#### UPOZORNĚNÍ:

Autor bakalářské práce nesmí při vytváření bakalářské práce porušit autorská práva třetích osob, zejména nesmí zasahovat nedovoleným způsobem do cizích autorských práv osobnostních a musí si být plně vědom následků porušení ustanovení § 11 a následujících autorského zákona č. 121/2000 Sb., včetně možných trestněprávních důsledků vyplývajících z ustanovení části druhé, hlavy VI. díl 4 Trestního zákoníku č.40/2009 Sb.



## **ABSTRAKT**

Tato bakalářská práce se zaměřuje na odhad tepové frekvence ze signálů fotopletysmografie (PPG). Práce využívá dvě databáze: CapnoBase a BUT PPG. Cílem je nejen přehledně popsat metody odhadu tepové frekvence ze signálů PPG, ale také navrhnut, implementovat a otestovat algoritmy pro spolehlivou detekci systolických vrcholů a stanovení tepové frekvence. Diskutovány jsou také výhody a omezení jednotlivých metod.

## **KLÍČOVÁ SLOVA**

fotopletysmografie, tepová frekvence, PPG, odhad tepové frekvence, systolické vrcholy, algoritmy, CapnoBase, BUT PPG

## **ABSTRACT**

This bachelor thesis focuses on heart rate estimation from photoplethysmographic (PPG) signals. The work utilizes two databases: CapnoBase and BUT PPG. The aim is not only to provide an overview of heart rate estimation methods from PPG signals but also to design, implement, and test algorithms for reliable detection of systolic peaks and heart rate determination. The advantages and limitations of each method are also discussed.

## **KEYWORDS**

photoplethysmography, heart rate, PPG, heart rate estimation, systolic peaks, algorithms, CapnoBase, BUT PPG



ŠIMČÁK, Petr. *Odhad tepové frekvence ze signálů PPG*. Bakalářská práce. Brno: Vysoké učení technické v Brně, Centrum sportovních aktivit, Ústav biomedicínského inženýrství, 2025. Vedoucí práce: doc. Ing. Jiří Kozumplík, CSc.



# Prohlášení autora o původnosti díla

**Jméno a příjmení autora:** Petr Šimčák

**VUT ID autora:** 226320

**Typ práce:** Bakalářská práce

**Akademický rok:** 2024/25

**Téma závěrečné práce:** Odhad tepové frekvence ze signálů PPG

Prohlašuji, že svou závěrečnou práci jsem vypracoval samostatně pod vedením vedoucí/ho závěrečné práce a s použitím odborné literatury a dalších informačních zdrojů, které jsou všechny citovány v práci a uvedeny v seznamu literatury na konci práce.

Jako autor uvedené závěrečné práce dále prohlašuji, že v souvislosti s vytvořením této závěrečné práce jsem neporušil autorská práva třetích osob, zejména jsem nezasáhl nedovoleným způsobem do cizích autorských práv osobnostních a/nebo majetkových a jsem si plně vědom následků porušení ustanovení § 11 a následujících autorského zákona č. 121/2000 Sb., o právu autorském, o právech souvisejících s právem autorským a o změně některých zákonů (autorský zákon), ve znění pozdějších předpisů, včetně možných trestněprávních důsledků vyplývajících z ustanovení části druhé, hlavy VI. díl 4 Trestního zákoníku č. 40/2009 Sb.

Brno .....  
.....  
podpis autora\*

---

\*Autor podepisuje pouze v tištěné verzi.



## PODĚKOVÁNÍ

Děkuji vedoucímu bakalářské práce doc. Ing. Jiřímu Kozumplíkovi, CSc. za trpělivost, hodnotné rady, laskavý přístup, konzultace, podklady k práci a odborné vedení.



# **Obsah**

<b>Úvod</b>	<b>21</b>
<b>1 Srdeční tep</b>	<b>23</b>
1.1 Srdeční tepová frekvence . . . . .	23
1.2 Faktory ovlivňující tepovou frekvenci . . . . .	23
1.3 Měření srdečního tepu . . . . .	24
<b>2 Fotopletysmograf</b>	<b>25</b>
2.1 Složení PPG signálu . . . . .	25
<b>3 Databáze</b>	<b>27</b>
3.1 CapnoBase . . . . .	27
3.2 BUT PPG . . . . .	27
<b>4 Elgendiho referenční algoritmus</b>	<b>29</b>
4.1 Obecná struktura algoritmu . . . . .	29
4.2 Předzpracování signálu . . . . .	29
4.3 Určení bloků zájmů a nalezení vrcholů . . . . .	31
<b>5 Vlastní algoritmus založený na detekci vrcholů</b>	<b>35</b>
5.1 Předzpracování PPG signálu . . . . .	35
5.2 Detekce vrcholů . . . . .	37
5.3 Výpočet tepové frekvence . . . . .	38
<b>6 Využití Hjorthových deskriptorů na odhad TF a kvality signálů</b>	<b>41</b>
6.1 Odhad TF pomocí Hjorthovy mobility . . . . .	41
6.2 Hodnocení kvality PPG signálů . . . . .	45
<b>7 Výsledky</b>	<b>49</b>
7.1 Výsledky pro databázi CapnoBase . . . . .	49
7.2 Výsledky pro databázi BUT PPG . . . . .	56
7.3 Výsledky automatického posouzení kvality . . . . .	56
<b>8 Diskuze</b>	<b>57</b>
<b>Závěr</b>	<b>59</b>
<b>Literatura</b>	<b>61</b>
<b>Seznam symbolů a zkratek</b>	<b>65</b>



# Seznam obrázků

2.1	Snímání PPG signálu . . . . .	25
2.2	Fiziologický popis PPG signálu . . . . .	26
3.1	Získání PPG signálu pro databázi BUT PPG . . . . .	28
4.1	Struktura Elgendiho algoritmu . . . . .	29
4.2	Elgendiho předzpracování PPG signálu . . . . .	30
4.3	Elgendiho zpracování pravidelného signálu . . . . .	33
4.4	Elgendiho zpracování nepravidelného signálu . . . . .	33
5.1	Vlastní amplitudová charakteristika Butterworthova filtru . . . . .	36
5.2	Vlastní detekce vrcholů . . . . .	37
5.3	Histogram IBI . . . . .	39
5.4	Vlastní zpracování signálů . . . . .	40
6.1	Schéma našeho algoritmu, který využívá Hjorthových deskriptorů . . . . .	41
6.2	Porovnání původního, filtrovaného a autokorelovaného signálu . . . . .	44
6.3	Porovnání kvality dle Orphanidou a referenční anotace z databáze BUT PPG . . . . .	48
6.4	Signál označený databází za kvalitní . . . . .	48
7.1	Srovnání metod detekující vrcholy pro minutové úseky . . . . .	51
7.2	Srovnání metod detekující vrcholy pro celý signál . . . . .	51
7.3	Chybný odhad TF pomocí vlastní vrcholové detekce . . . . .	52
7.4	Chybný odhad TF pomocí Hjorthových deskriptorů u nekvalitního signálu . . . . .	52
7.5	Bland-Altmanova analýza pro metody detekující vrcholy . . . . .	54
7.6	Bland-Altmanova analýza pro metodu využívající Hjorthovy deskrip- tory . . . . .	55



## **Seznam tabulek**

7.1	Srovnání metod odhadu TF na databázi CapnoBase . . . . .	50
7.2	Srovnání metod odhadu TF na databázi BUT PPG . . . . .	56



# **Seznam výpisů**



# Úvod

Tepová frekvence je jedním z klíčových zdravotních parametrů, který poskytuje důležité informace o stavu kardiovaskulárního systému subjektu. Měření a monitorování srdeční tepové frekvence se stalo nepostradatelným nástrojem nejen v medicíně, ale také ve sportovní vědě a kondičním tréninku. Tradiční metody měření tepové frekvence, jako je EKG (Elektrokardiogram), jsou přesné, ale jejich nevýhodami jsou vyšší cena a uživatelská nepřívětivost v používání EKG systémů. V posledních letech získává na popularitě PPG (Fotopletysmograf). Jedná se o neinvazivní a relativně levnou metodu, která umožňuje monitorovat tepovou frekvenci pomocí optických senzorů.

Fotopletysmografie funguje na principu detekce změn objemu krve v tkáni pomocí světla, které je absorbováno nebo reflektováno. Výhodou PPG je možnost integrace do nositelných zařízení, jako jsou chytré hodinky nebo fitness náramky, což umožňuje nepřetržité monitorování tepové frekvence v reálném čase bez zásahu do běžného života měřeného.

Cílem této bakalářské práce je popsat metody odhadu tepové frekvence z PPG signálů a navrhnout vlastní algoritmy, které umožní spolehlivé stanovení tepové frekvence. K otestování algoritmů budou využity databáze PPG signálů: CapnoBase a BUT PPG (Brno University of Technology Smartphone PPG Database).



# 1 Srdeční tep

Srdeční tep, nazývaný též pulz, představuje jeden z nejzákladnějších zevních projevů srdeční činnosti. Jedná se o tlakovou vlnu, která vzniká při systole (stahu) srdce a šíří se krevním řečištěm do celého těla. Tuto tlakovou vlnu lze vnímat na povrchu těla (tzv. palpačně), konkrétně v místech, kde vedou tepny v relativně mělkých oblastech. A to na příklad na zápěstí (a. radialis) nebo na krku (a. carotis) [4, 19].

Význam srdečního tepu a jeho frekvence (počtu úderů za minutu) je zásadní v klinické praxi i ve výzkumu. Vzhledem k tomu, že tepová vlna vychází přímo z cyklické práce srdce, poskytuje nám relativně přesnou a snadno dostupnou informaci o srdeční aktivitě. Srdeční tep i jeho variabilita se dnes běžně využívají k orientačnímu posouzení kardiovaskulárního zdraví a k monitorování reakce kardiovaskulárního systému na různé podněty a zátěž [21].

## 1.1 Srdeční tepová frekvence

Tepová frekvence (TF) je běžně užívanou veličinou pro základní posouzení srdeční činnosti. Je definována jako počet srdečních cyklů (systol a diastol) za jednu minutu. U zdravého dospělého jedince v klidovém stavu se nejčastěji pohybuje v rozmezí 60 až 90 úderů za minutu. Maximální rozsah TF lze vypočítat, když se vezme v potaz pohlaví, věk a váha [4]. Obecně se ale považují za hraniční hodnoty 30 až 200 úderů za minutu [11]. Pro klidový stav jsou hodnoty pod 60 úderů za minutu označovány jako bradykardie, u 90-ti úderů za minutu pak hovoříme o tachykardii [4, 20].

Důležitým aspektem ovlivňujícím TF je i pravidelnost srdečního rytmu. Pravidelné intervaly mezi jednotlivými údery signalizují rovnoměrné srdeční stahy. Nepravidelnosti se označují jako arytmie, které mohou poukazovat na různá onemocnění, např. fibrilace síní či extrasystoly [4].

## 1.2 Faktory ovlivňující tepovou frekvenci

TF může kolísat v závislosti na mnoha faktorech, které lze rozdělit na vnitřní (endogenní) a vnější (exogenní). K vnitřním faktorům patří například momentální zdravotní stav, tělesná kondice, hormonální vlivy nebo genetické predispozice. Mezi vnější faktory lze řadit fyzickou aktivitu, působení stresu, emoční zátěž či užití stimulantů (např. kofein nebo nikotin) [21].

Významným determinantem srdečních pulzů je obecně fyzická aktivita - během cvičení či zvýšené tělesné námahy musí organismus zajistit vyšší příjem kyslíku a živin do zatížených svalů, čehož dosahuje zrychlením srdeční aktivity. Podobně i

stresové situace či emoční reakce vedou ke stimulaci sympatického nervového systému, jenž zvyšuje srdeční tep. Naopak parasympatický nervový systém v klidových stavech srdeční činnost brzdí [21].

## 1.3 Měření srdečního tepu

Existuje řada způsobů, jak TF měřit a kvantifikovat. Základní dělení vychází z rozlišení mezi manuálními a instrumentálními metodami.

Tradičním, jednoduchým a dostupným postupem manuálního měření je již zmíněné palpační měření tepu v kapitole 1. Při něm se prsty (typicky ukazovák a prostředník) přiloží na vhodnou tepnu, často vřetenní tepnu na zápěstí (a. radialis), a po stanovenou dobu se počítají údery. Manuální metoda je i přes svoji jednoduchost relativně spolehlivá, avšak nemusí být ideální pro detekci nepravidelného rytmu nebo může být chybová při nepozornosti vyšetřujícího [20].

Instrumentální metoda je taková, která využívá moderní přístroje, jako jsou fitness náramky, chytré hodinky či specializované pulzmetry, umožňují pohodlné, dlouhodobé a relativně přesné měření srdečního tepu. Často využívá principu fotopletysmografie (PPG), kdy senzor vyhodnocuje změny průtoku krve podle odrazivosti světla ve tkáni. Ve sportovním tréninku se uplatňují také hrudní pásy, které snímají EKG a monitorují tep spolehlivě i při vyšších zátěžích.

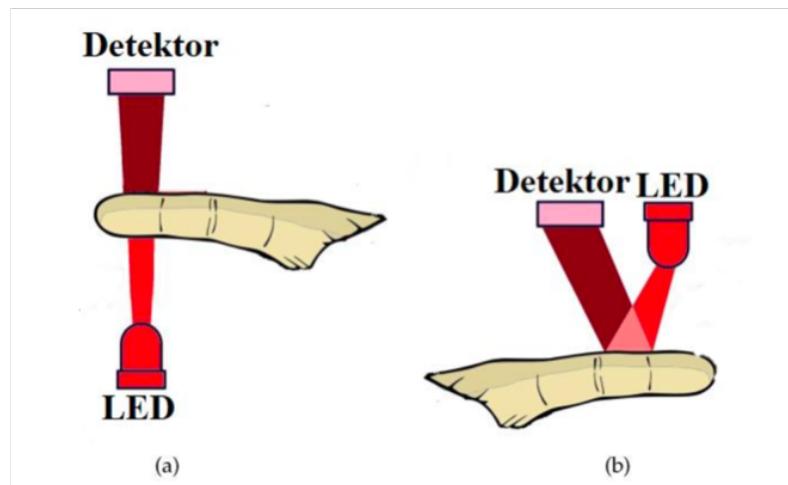
Výsledkem měření je výše popsaná tepová frekvence popsaná v podkapitole 1.1, vyjádřená v počtech úderů za minutu. Moderní přístroje nabízejí trvalé monitorování s automatickým záznamem tepové frekvence, což usnadňuje dlouhodobé sledování a vyhodnocování dat.

## 2 Fotopletysmograf

Fotopletysmografie (PPG) je neinvazivní optická metoda sloužící k monitorování změn objemu krve v mikrovaskulárním řečišti tkáně, obvykle na prstu, zápěstí či ušním lalůčku [22]. Zejména díky snadné integraci do nositelných zařízení (např. chytrých hodinek) a relativně nízkým nákladům na realizaci se PPG stává klíčovým nástrojem pro dlouhodobé sledování kardiovaskulárních parametrů, jako je tepová frekvence (TF), saturace krve kyslíkem ( $\text{SpO}_2$ ) či hodnocení variability tepových intervalů [10].

Na Obr. 2.1 jsou znázorněny dvě základní měřicí konfigurace. Transmisní režim (a), kde je zdroj světla a fotodetektor na opačných stranách tkáně (typicky při měření na prstu či ušním lalůčku). A reflexní režim (b), zde je umístěn zdroj světla i detektor na téže straně tkáně, což se používá v běžných sportovních zařízeních, jakou jsou chytré hodinky. Tento režim je z morfologických důvodů náchylnější k chybám [17].

Metoda PPG je založena na měření intenzity světla, která se po interakci s tkání dostane k detektoru. Množství absorbovaného/odraženého světla závisí na aktuálním průtoku krve, který je modulován srdečními cykly [22].



Obr. 2.1: Transmisní režim (a) a reflexní režim (b), upraveno z [4].

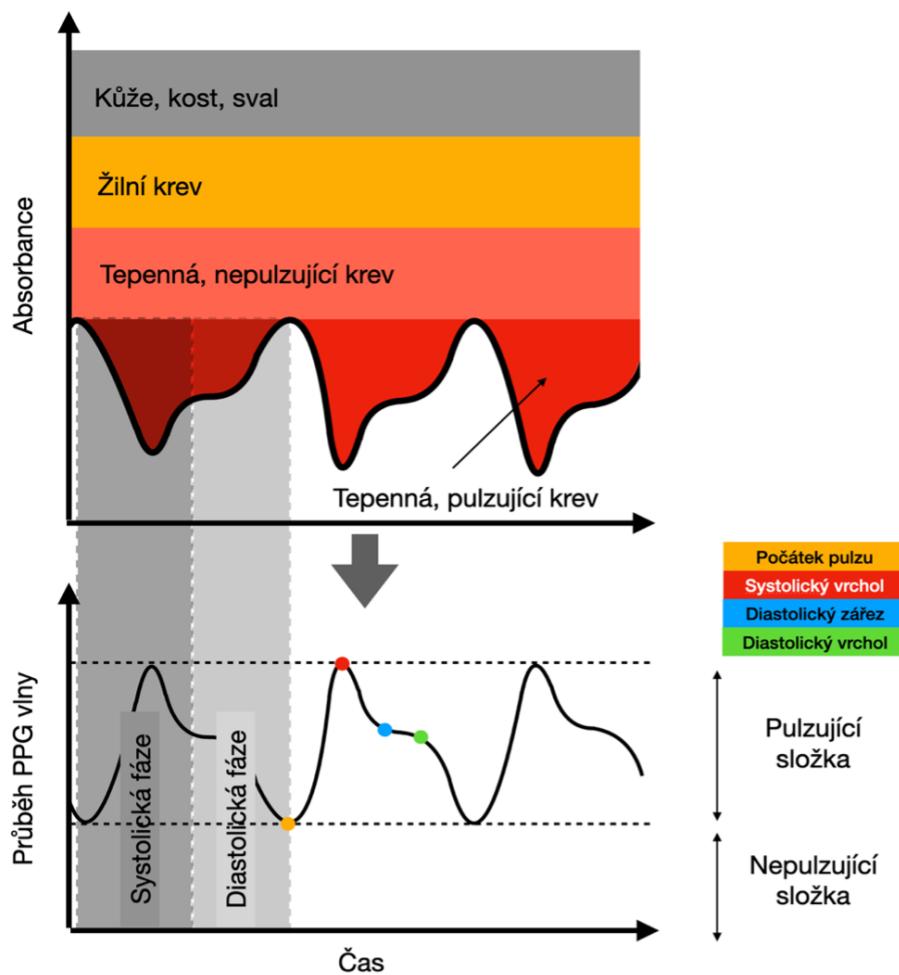
### 2.1 Složení PPG signálu

Jak ukazuje Obr. 2.2, naměřený PPG signál zahrnuje *pulzní* složku, synchronizovanou se srdeční aktivitou, a stabilní *nepulzní* složku. *Pulzní* složka odráží periodické změny objemu arteriální krve v rozsahu typického frekvenčního pásma srdeční činnosti (zhruba 0,5–3 Hz) a je klíčová pro přesnou detekci TF. *Nepulzní* složka

představuje základní linii danou absorpcí tkání a žilní krve; ovlivňuje ji například barva kůže, okolní osvětlení a anatomické poměry měřené oblasti [4, 22]. Je důležité si uvědomit, že PPG signál je inverzní k měřenému optickému signálu, protože reprezentuje objem krve v tkání, nikoli množství světla dopadajícího na senzor, což je patrné i z Obr. 2.2.

Za počátek pulzu v PPG signálu se obvykle považuje nejnižší bod předcházející systolické fázi, který odpovídá minimálnímu objemu krve v měřené oblasti. Pro výpočet TF se využívají systolické vrcholy, tedy body s maximálním objemem krve, z nichž lze určit intervaly mezi srdečními údery a následně stanovit TF.

Po systolickém vrcholu přichází diastola, což je fáze srdečního cyklu, během které dochází k relaxaci srdečního svalu a plnění srdce krví. V průběhu diastoly bývá často patrný typický dikrotický zářez, který odráží elastické vlastnosti cévní stěny a uzávěr aortální chlopně. Jeho přítomnost a tvar mohou poskytovat užitečné informace o stavu kardiovaskulárního systému [10, 22].



Obr. 2.2: Princip získání PPG křivky a její popis. Upraveno z [22].

## 3 Databáze

V této práci jsme využívali dvě databáze fotopletysmografických signálů: *CapnoBase* a *Brno University of Technology Smartphone PPG Database*, pro kterou budeme v této práci používat zkrácený název BUT PPG.

Na těchto databázích jsme testovali a porovnávali výsledky použitých algoritmů. U databáze CapnoBase jsme porovnávali naměřené systolické vrcholy s referenčními hodnotami a díky tomu jsme porovnávali i rozdíl v srdeční tepové frekvenci (TF). U databáze BUT PPG nebyly referenční hodnoty systolických vrcholů k dispozici, ale byly zde referenční hodnoty TF signálů a ty jsme porovnávali s naměřenými výsledky.

### 3.1 CapnoBase

CapnoBase je veřejně dostupná databáze, která obsahuje osmiminutové záznamy od 42 dětských i dospělých pacientů, podstupujících plánované chirurgické zákroky včetně anestézie [3].

Součástí databáze jsou PPG, EKG a respirační signály, se vzorkovací frekvencí 300 Hz. Pro každý záznam jsou navíc ručně označeny systolické vrcholy v PPG, odvozené z EKG, což umožňuje přesné ověření správnosti detekce tepů. Autoři však nedoporučují databázi používat k trénování či doladování algoritmů [3]. Proto jsme ji použili pouze k testování použitých algoritmů a k porovnání výsledků s referenčními hodnotami.

Díky svým vlastnostem je CapnoBase vhodná k posouzení robustnosti a přesnosti metod v klinických situacích [8, 6].

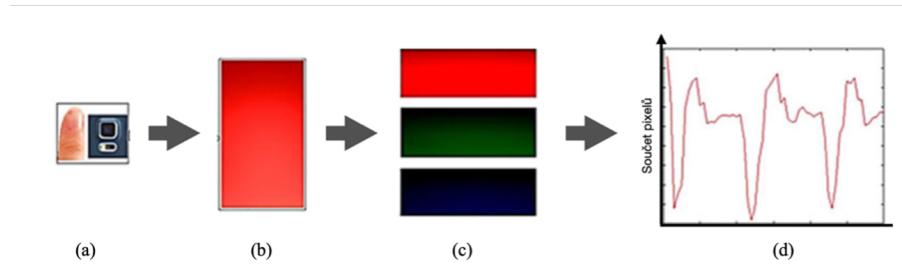
### 3.2 BUT PPG

Databáze BUT PPG vznikla na Fakultě elektrotechniky a komunikačních technologií VUT za účelem zkoumání kvality PPG záznamů a odhadu TF. V nové rozšířené verzi obsahuje 3,888 desetisekundových měření od 50 dobrovolníků (25 žen a 25 mužů) ve věku 19 až 76 let, a to v klidu i při různých typech pohybových aktivit. Fotopletysmografické záznamy byly pořízeny chytrými telefony *Xiaomi Mi9* a *Huawei P20 Pro* se vzorkovací frekvencí 30 Hz. Pro referenční EKG a akcelerometrická (ACC) data byl použit mobilní senzor *Bittium Faros 360* (nebo 180) se vzorkovacími frekvencemi 1,000 Hz pro EKG a 100 Hz pro ACC [1, 2]. Surový PPG signál byl extrahouván z červené složky nahraného videa (viz. Obr. 3.1).

Každý PPG záznam byl synchronizován s EKG a rozdělen do desetisekundových segmentů, které následně hodnotilo tři až pět expertů [2]. Pro označení kvality vycházel výhradně z rozdílu mezi TF odhadnutou z PPG a referenční tepovou frekvencí z EKG. Pokud byla odchylka do pěti úderů za minutu, bylo dané měření označeno jako „dobré“ (1), jinak jako „špatné“ (0). Tato hranice vychází z mezinárodní normy IEC 60601-2-27 a v databázi BUT PPG je aplikována ještě přísněji [1].

Přibližně polovina záznamů vznikla přiložením prstu na zadní kameru a LED, druhá pak snímáním ucha v poloze připomínající telefonování. V novější části databáze se rozšiřuje množství subjektů i situací, včetně manipulací s osvětlením, vyšším tlakem prstu na čočku, mluvením či chůzí, a nově se přidávají i údaje o krevním tlaku, glykémii a saturaci krve kyslíkem.

Díky této variabilitě podmínek a bohatým anotacím je BUT PPG unikátním zdrojem pro testování robustnosti algoritmů detekce TF a pro posuzování použitelnosti krátkých PPG signálů z mobilního telefonu v reálné praxi.



Obr. 3.1: Záznam videa na kameru mobilního telefonu (a), jeden vybraný snímek ze záznamu (b), snímek rozložen na tři barevné složky (c), PPG signál vykreslený z červené složky (d), upraveno z [5].

Spojením klinicky orientované databáze CapnoBase a mobilně zaměřené BUT PPG vzniká možnost vzájemného porovnání a ověření přesnosti algoritmů, které musejí obstát v rozdílných kontextech: v relativně stabilním, klinickém, prostředí a v krátkých záznamech z chytrého telefonu.

# 4 Elgendiho referenční algoritmus

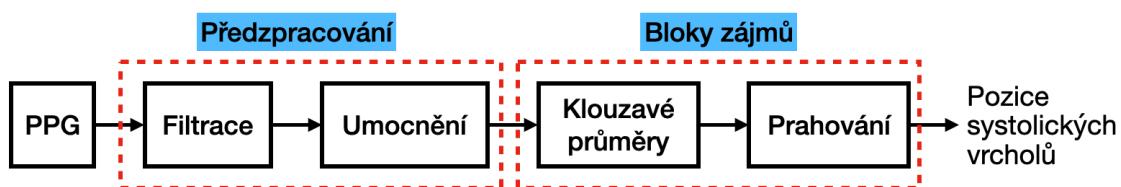
Tato kapitola popisuje, jak lze ve fotopletysmografickém (PPG) signálu nalézt systolické vrcholy s využitím Elgendiho algoritmu, který je implementován v knihovně NeuroKit2.

Tato knihovna reaguje na „krizi reprodukovanosti“, což je problém, kdy vědecké studie nelze opakovat kvůli nedostupnosti kódu a dat. Proto nabízí otevřený zdrojový kód, strukturovanou dokumentaci i podporu k začleňování funkcí přímo do výzkumných prací [14]. Zdrojový kód pro NeuroKit2 je dostupný na <https://github.com/neuropsychology/NeuroKit> a dokumentace na <https://neurokit2.readthedocs.io/>. Knihovnu je možné průběžně modifikovat a vyvíjet.

V kapitole 2 byly již podrobně shrnutý principy PPG, proto se zde zaměříme na samotnou detekci vrcholů a její realizaci.

## 4.1 Obecná struktura algoritmu

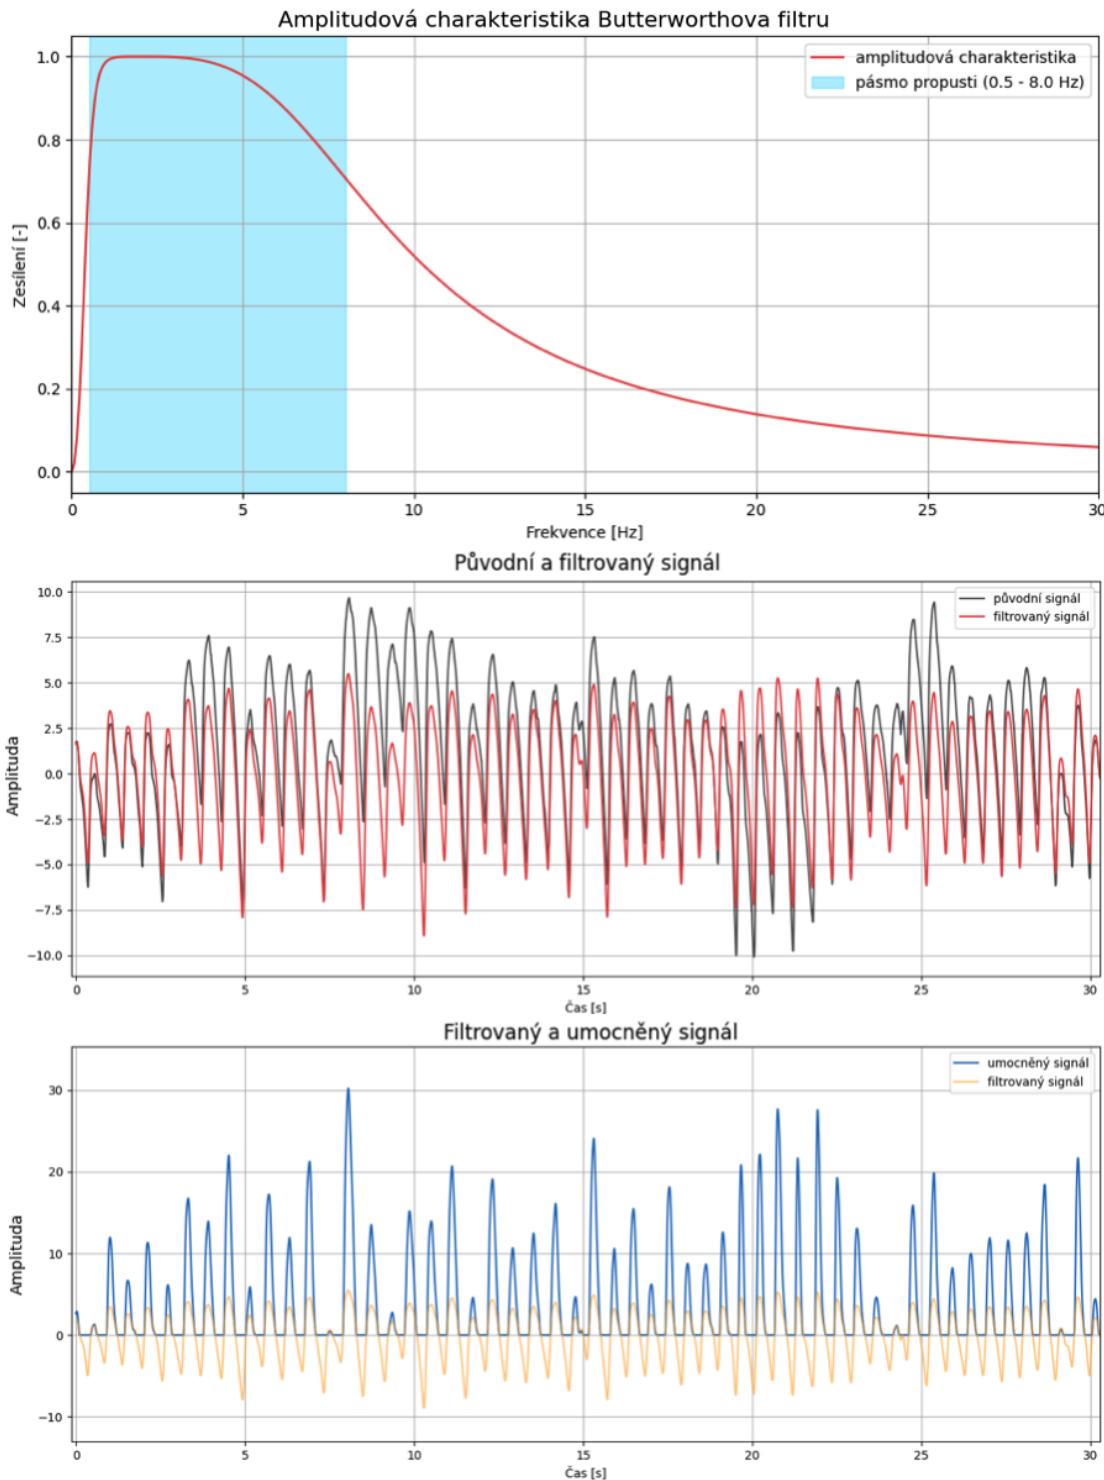
Algoritmus se skládá z několika kroků: *filtrace* pomocí pásmové propusti, *umocnění* signálu, vytvoření dvou *klouzavých průměrů* a dvou *prahů* (Obr. 4.1) [13]. Vstupem je surový fotopletysmografický záznam, zatímco výstupem jsou konkrétní časové pozice nalezených systolických vrcholů.



Obr. 4.1: Zjednodušené schéma Elgendiho algoritmu [13].

## 4.2 Předzpracování signálu

Pro samotnou detekci vrcholů připraví Elgendi [13] signál pomocí filtrace a umocnění kladných hodnot. Elgendi používá Butterworthův filtr druhého rádu, který je zpracován v přímém i reverzním směru (tzv. filtrace s nulovým fázovým posuvem), ale v knihovně NeuroKit2 je implementován filtr třetího rádu. My jsme se rozhodli přenastavit funkci v knihovně tak, aby odpovídala původnímu filtru druhého rádu, což je náš jediný zásah do kódu knihovny. Filtr je nastaven jako pásmová propust



Obr. 4.2: Filtrace PPG signálu pomocí Butterworthova filtru a umocnění.

s dolní a horní mezí 0,5 Hz a 8 Hz, který má potlačit ty složky signálu, které odpovídají šumu a kolísání nulové izolinie [13]. Na Obr. 4.2 je ukázka amplitudové charakteristiky filtru a porovnání původního a filtrovaného úseku signálu.

Po filtraci je kaldná část signálu umocněna na druhou viz. (4.1). To je provedeno s cílem zdůraznit rozdíly mezi systolickou vlnou a ostatními složkami, jako jsou diastolické zářezy nebo šum [13]. Výsledná hodnota  $y[n]$  po umocnění je dána vztahem:

$$y[n] = \begin{cases} Z[n]^2, & \text{pokud } Z[n] > 0, \\ 0, & \text{pokud } Z[n] \leq 0. \end{cases} \quad (4.1)$$

kde  $Z[n]$  představuje již vyfiltrovaný signál. Porovnání filtrovaného a umocněného signálu je ilustrováno na Obr. 4.2.

### 4.3 Určení bloků zájmu a nalezení vrcholů

Po úvodní filtrace a umocnění fotopletysmografického signálu, vypočítává Elgendiho algoritmus dva klouzavé průměry (MA), které se od sebe liší v samotné šířce průměrujícího okna [13].

Kratší okno  $W_1$  je nastaveno tak, aby sloužilo ke zdůraznění systolické špičky, zatímco delší okno  $W_2$  se vybralo tak, aby zdůraznilo období celého srdečního cyklu. Tyto konstanty odpovídají šírkám oken v milisekundách, ve kterých se počítají klouzavé průměry (4.2) a (4.3). Pro vypočítání konkrétních velikostí oken bylo provedeno metodou „hrubé sily“ vhodných parametrů tak, že se vyzkoušely různé kombinace délky těchto a dalších a konstant. Jako nejlepší kombinace se vybrala ta, po které dosahoval algoritmus nejvyššího skóre v citlivosti (Se) a pozitivní prediktivní hodnotě (PPV) na trénovací sadě dat [13]. Pro  $W_1$  byla zvolena hodnota 111 (odpovídající milisekundám) a pro  $W_2$  hodnota 667.

#### Výpočet klouzavých průměrů

Elgendi definuje umocněný a vyfiltrovaný PPG signál jako  $y[n]$ . Klouzavý průměr s kratším oknem  $MA_{peak}$  se pro každý bod  $n$  vypočítá rovnicí

$$MA_{peak}[n] = \frac{1}{W_1} (y[n - \frac{W_1 - 1}{2}] + \dots + y[n] + \dots + y[n + \frac{W_1 - 1}{2}]), \quad (4.2)$$

kde je  $W_1$  konstanta popsána v podkapitole 4.3 [13]. Podobně se s delším oknem  $W_2$  vypočítá  $MA_{beat}$ , který reprezentuje přibližnou délku jednoho srdečního cyklu:

$$MA_{beat}[n] = \frac{1}{W_2} (y[n - \frac{W_2 - 1}{2}] + \dots + y[n] + \dots + y[n + \frac{W_2 - 1}{2}]). \quad (4.3)$$

Výsledky výpočtů jsou zobrazeny na Obr. 4.3 a Obr. 4.4. Tyto klouzavé průměry slouží k vypočítání  $THR_1$  a následných bloků zájmu, které vedou k určení systolických vrcholů.

## Nastavení dvou dynamických prahů

Pro další zpracování se zvolí dvě prahové hodnoty. První dynamický prah  $THR_1$  se vypočítá posunutím signálu  $MA_{beat}$  o konstantu  $\beta$  vynásobenou průměrnou hodnotou umocněného signálu  $\bar{z}$  viz. (4.4). Tato průměrná hodnota se vypočítává z celého umocněného signálu.  $\beta$  je jedním z parametrů, který se nastavuje metodou „hrubé síly“ a nejlepší výsledky vyšly, když se  $\beta$  nastavila na hodnotu 2 [13].

$$THR_1[n] = MA_{beat}[n] + \beta \cdot \bar{z}. \quad (4.4)$$

První prah je vykreslen na Obr. 4.3 a Obr. 4.4 společně s klouzavými průměry a umocněným signálem. Z těchto obrázků je patrné, že parametry  $\beta$  ani  $\bar{z}$  nemají na prah  $THR_1$  příliš významný viditelný efekt, tudíž je křivka  $THR_1$  velmi podobná křivce  $MA_{beat}$ .

Porovnáním  $MA_{peak}[n]$  s  $THR_1[n]$  získáme časové úseky (tzv. bloky zájmu), které odpovídají částem, kde je signál nad úrovní  $MA_{beat}$ .

Druhý prah  $THR_2$  slouží k pročištění již stanovených bloků zájmů a je roven konstantě  $W_1$ . Elgendi využívá tento prah pro eliminaci všech bloků, které jsou kratší než předem stanovená konstanta reprezentující očekávanou šířku systolické vlny [13].

## Určení bloků zájmu

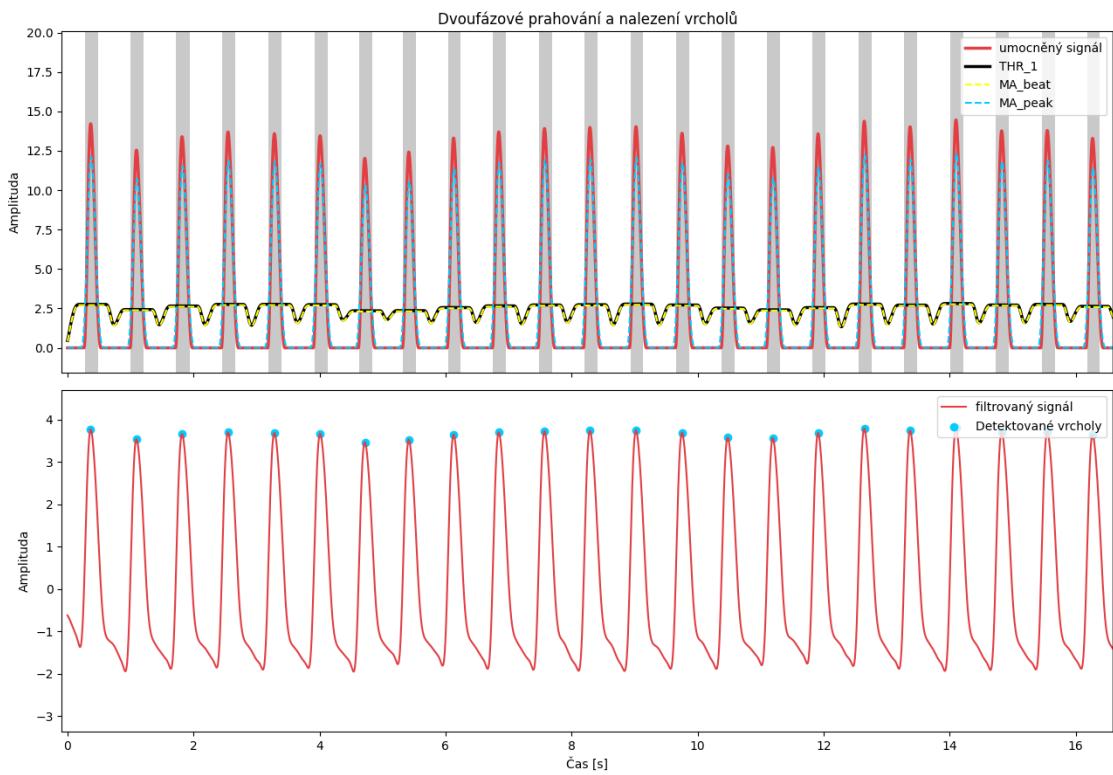
Porovnáním výše uvedeného klouzavého průměru  $MA_{peak}$  a prvního prahu ( $THR_1$ ) jsou určeny bloky zájmu. Tyto bloky jsou definovány jako úseky, kde je  $MA_{peak}$  větší než  $THR_1$  a zároveň jejich šířka je větší než  $THR_2$  viz. (4.5) [13]. Bloky zájmu jsou zobrazeny jako šedé úseky na Obr. 4.3 a 4.4.

$$\{n : MA_{peak}[n] > THR_1[n] \wedge okno > THR_2\}. \quad (4.5)$$

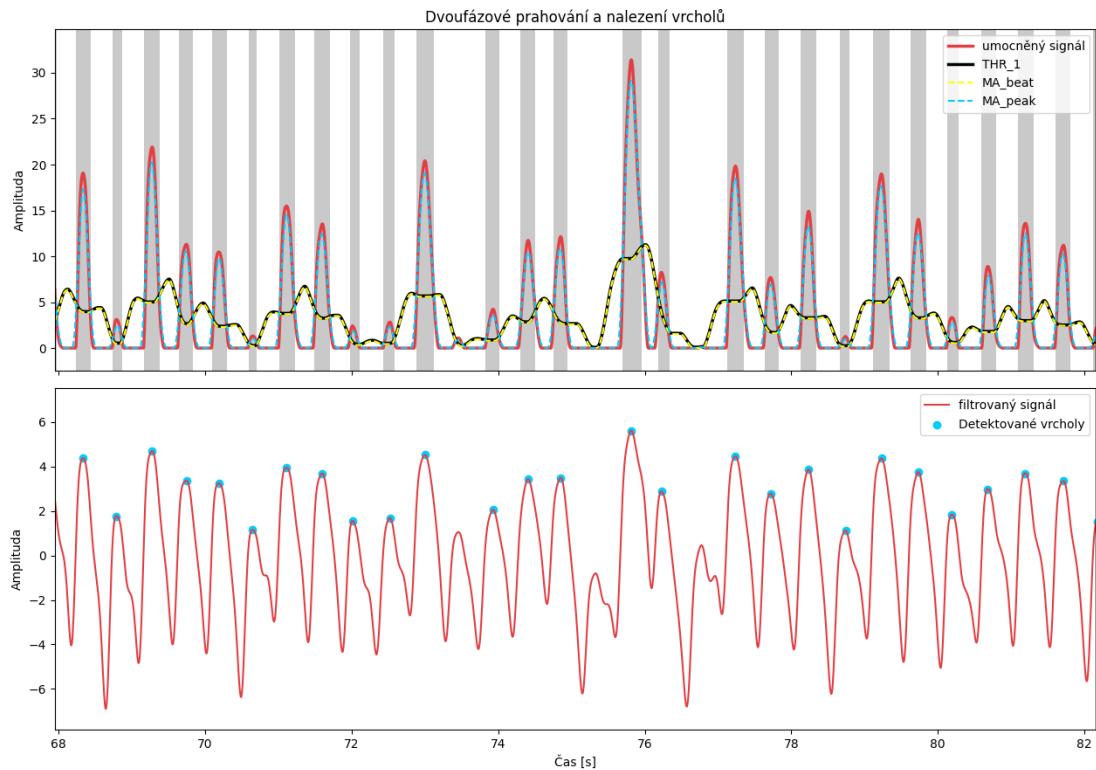
Na Obr. 4.4 vidíme tři systolické vrcholy, které nebyly detekovány (kolem 74., 75. a 77. sekundy). U prvního z nich je patrné, že umocněný signál překračuje  $THR_1$ , avšak blok je příliš krátký, a proto je vyřazen. Druhý a třetí vrchol mají ve filtrovaném signálu příliš nízkou amplitudu, což způsobuje, že po umocnění nejsou dostatečně výrazné.

## Nalezení vrcholů

Samotné systolické vrcholy jsou určeny jako lokální maxima v oblastech bloků zájmu. Funkce *find\_peaks* z knihovny NeuroKit2 zpracovává jednodimenzionální signál a porovnáním hodnot v každém bloku zájmu určuje lokální maxima [14].



Obr. 4.3: Nastavení bloků zájmu a určení systolických vrcholů pro pravidelný signál.



Obr. 4.4: Nastavení bloků zájmu a určení systolických vrcholů pro nepravidelný signál.



# 5 Vlastní algoritmus založený na detekci vrcholů

V této kapitole se zaměříme na popis vlastního algoritmu pro detekci systolických vrcholů a odhad srdeční tepové frekvence z fotopletysmografických signálů.

Našim cílem je vytvořit jednoduchý a efektivní algoritmus, který poskytne spolehlivé výsledky pro různé typy PPG signálů.

## 5.1 Předzpracování PPG signálu

### Načtení signálů

Jelikož pracujeme se dvěma databázemi - *CapnoBase* a *BUT PPG*, výstupem po načtení signálů jsou dvě odlišné knihovny, které zpracováváme samostatně později. Obě databáze mají odlišnou strukturu souborů a formát signálů, což vyžaduje samostatný přístup při jejich načítání.

Databáze *CapnoBase* obsahuje signály uložené v `.mat` souborech. Z každého souboru načítáme signál PPG, referenční systolické vrcholy a vzorkovací frekvenci [3]. Navíc si vygenerujeme referenční tepovou frekvenci (TF) z referenčních vrcholů, a to pomocí stejného algoritmu, který později použijeme pro výpočet TF z našich detekovaných vrcholů. Pro účely čitelnější vizualizace a zpracování ukládáme též identifikátor záznamu, což jsou první čtyři znaky názvu souboru.

Oproti tomu databáze *BUT PPG* používá formát WaveForm Database (WFDB) a obsahuje PPG záznamy v `.dat` a `.hea` souborech. Tato databáze původně obsahovala 48 záznamů, které byly později rozšířeny o dalších 3 840 záznamů. Při načítání bylo nutné zohlednit, že starší PPG signály byly uloženy v jednom kanálu, zatímco ostatní signály byly rozděleny do tří kanálů, odpovídajících třem různým barevným složkám signálu [2]. Z novějších záznamů jsme jako referenční PPG signál vybrali pouze červenou složku, která nejvíce odpovídá standardnímu PPG signálu.

Výsledkem načtení jsou dvě knihovny, které obsahují dostupná data z obou databází ve formátu vhodném pro další zpracování.

### Rozdelení záznamů

Záznamy v databázi *CapnoBase* jsou dlouhé osm minut. Tuto délku jsme považovali za nevhodnou pro výpočet tepové frekvence, protože výsledná hodnota TF by mohla být zkreslená kratšími úseky se zvýšenou nebo sníženou TF. Mohlo by se tedy stát, že referenční a naše tepové frekvence by vykazovaly podobné výsledky, přestože by se v jednotlivých úsecích mohly výrazně lišit.

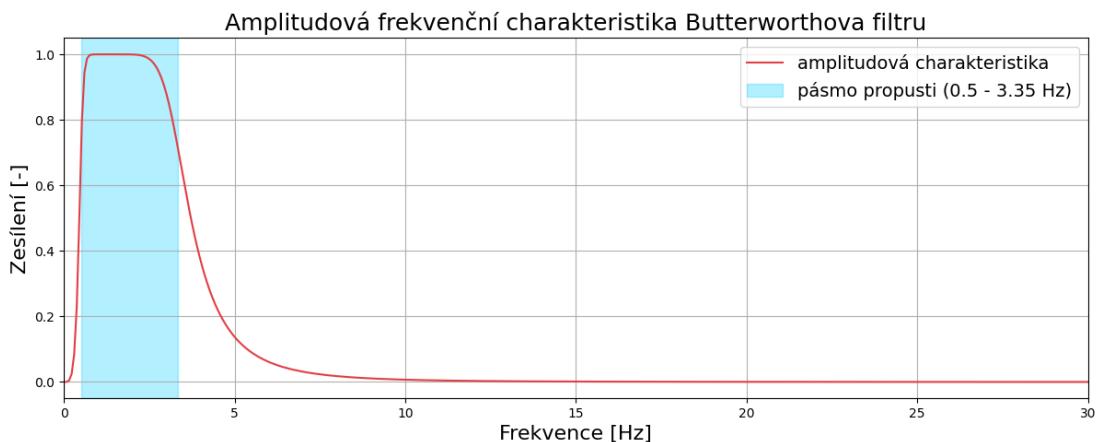
Proto jsme přistoupili k rozdělení každého dlouhého záznamu na kratší, minutové segmenty, které měly pětiprocentní překryv. Takový překryv byl zaveden proto, abychom testovali algoritmy na všech vrcholech v záznamu a nedošlo k vynechání některých vrcholů na začátku nebo na konci segmentu. Navíc takový překryv vyhovoval i proto, že počet oken popsaných v podkapitole 5.2 se rozšíří pouze o jeden. Rozdělený signál je znázorněn na Obr. 5.2. Výsledné, 63 sekund dlouhé úseky byly dále považovány za samostatné signály, které byly zpracovány jednotlivě.

## Filtrace

Po načtení a případném rozdělení záznamů následovalo filtrování signálu. Na filtraci jsme použili pásmový filtr čtvrtého rádu typu Butterworth, jehož parametry jsme nastavili s ohledem na fyziologické vlastnosti PPG signálu. Dolní mez frekvence byla nastavena na 0,5 Hz (30 úderů za minutu) a horní mez na 3,35 Hz (201 úderů za minutu). Amplitudová charakteristika filtru je znázorněna na Obr. 5.1.

Tento rozsah byl zvolen tak, aby odstranil velmi pomalé změny v signálu, například dechovou frekvenci. Zároveň tak, aby potlačil vysokofrekvenční šum, který by mohl negativně ovlivnit detekci vrcholů. V nastavení prahů vycházíme z obecných hraničních hodnot lidské tepové frekvence popsané v kapitole 1.1.

Samotný Butterworthův filtr byl zvolen pro jeho rovnost v propustném pásmu, takže amplitudová charakteristika filtru je hladká a nevykazuje vlnění, které je typické pro některé jiné typy filtrů. Čtvrtý rád zajišťuje dostatečný kompromis mezi strmostí přechodu a numerickou stabilitou filtru. Pro odstranění fázového posunu, který je charakteristický pro použitý filtr, jsme použili filtr s nulovou fází, jenž provádí filtraci v obou směrech.



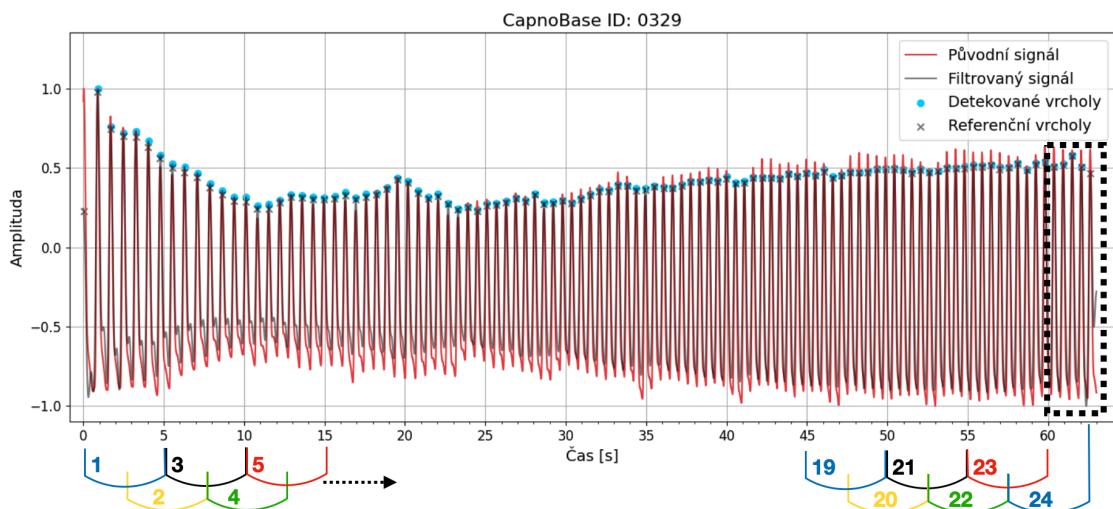
Obr. 5.1: Amplitudová charakteristika Butterworthova filtru.

Výsledky filtrace a standardizace jsou zřetelné z Obr. 5.4. Po těchto krocích jsme získali očištěný a normalizovaný signál, připravený pro detekci systolických vrcholů.

## 5.2 Detekce vrcholů

Hledání vrcholů probíhá v pětisekundových oknech, která se překrývají o 50%. Funguje to tak, že nejprve analyzujeme prvních 5 sekund signálu, poté posuneme okno o 2,5 sekundy a analyzujeme dalších 5 sekund, přičemž prvních 2,5 sekund se překrývají s předchozím oknem. Tímto způsobem pokryjeme celý signál a zajistíme, že žádný vrchol nebude vynechán. Na jeden minutový signál obvykle připadá 23 oken, ale protože máme 5% překryv celého minutového záznamu, délka výsledného signálu je 63 sekund, a proto analyzujeme o jedno okno navíc. Vizuálně je to znázorněno na Obr. 5.2.

Pro celý signál jsme nastavili dva prahy. První prahová hodnota odpovídala minimální výšce vrcholu, který považujeme za platný. Tato hodnota byla empiricky nastavena na 0,3 a měla za cíl odlišit skutečné vrcholy od diastolických zářezů a šumu. Druhá prahová hodnota odpovídala minimálnímu časovému intervalu mezi dvěma po sobě jdoucími vrcholy. Byla nastavena na počet vzorků odpovídající dvěma stům tepům za minutu.



Obr. 5.2: Druhá minuta záznamu s vizualizací oken a s překryvem.

V každém okně jsme provedli standardizaci a normalizaci signálu do rozsahu od  $-1$  do  $1$ , abychom zajistili, že nastavené prahy budou co nejpřesněji odpovídat předpokládaným systolickým a diastolickým fázím PPG křivky. Tyto kroky jsou důležité, protože maximální hodnoty systolické vlny se mohou v průběhu času měnit, jak je patrné z Obr. 5.2, což by vedlo k falešně negativním výsledkům.

Samotná detekce vrcholů je realizována jednoduchým algoritmem hledající lokální maxima. Funguje tak, že každý vzorek v okně je porovnán se svým předchozím a následujícím sousedem. Pokud je jeho hodnota větší než hodnota obou sousedů

a současně překračuje oba zadané prahy, je tento vzorek označen jako systolický vrchol.

V závěru se odstraní případné duplicitní detekce, které vznikly vlivem překrývání oken. Vrchol detekovaný na stejném časovém vzorku ve dvou sousedních oknech je ponechán pouze jednou. Tento krok je důležitý zejména pro budoucí hodnocení algoritmu, kde pracujeme nejen s informací o pozici vrcholů, ale také s jejich počtem v jednotlivých úsecích. Duplicitní detekce by vedly ke zkreslení metrik a nesprávné interpretaci výsledků.

Posledním krokem je zpětná kontrola minimální vzdálenosti mezi detekovanými vrcholy. Bez této kontroly by se mohlo stát, že bychom detekovali vrchol na konci prvního okna a u dalšího okna bychom detekovali nový vrchol příliš blízko, protože si nové okno nepamatuje pozici posledního, předchozího vrcholu. Příklad takové chyby je zobrazen na Obr. 5.4, ve druhém okně.

### 5.3 Výpočet tepové frekvence

Základní veličinou pro tento výpočet je interval mezi dvěma po sobě následujícími vrcholy, označovaný jako tepový interval - IBI (z anglického „Inter-Beat Interval“). Ten jsme vypočítali tak, že jsme vzali rozdíl mezi časem detekce aktuálního vrcholu a časem detekce předchozího vrcholu:

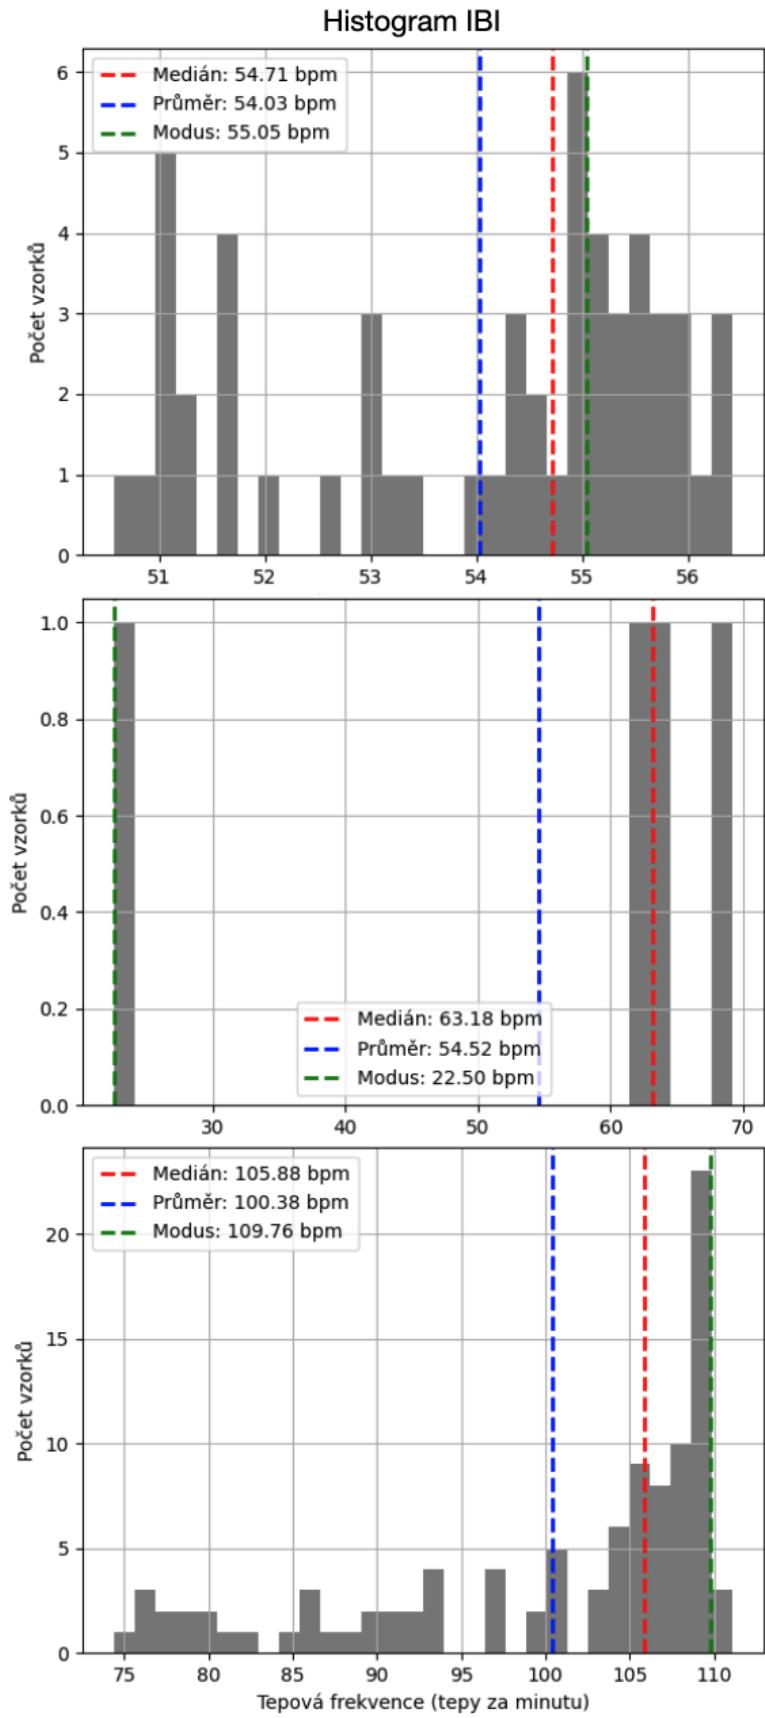
$$IBI_i = t_i - t_{i-1}. \quad (5.1)$$

Výsledkem je sekvence hodnot, které odpovídají časovým intervalům mezi jednotlivými systolickými vrcholy.

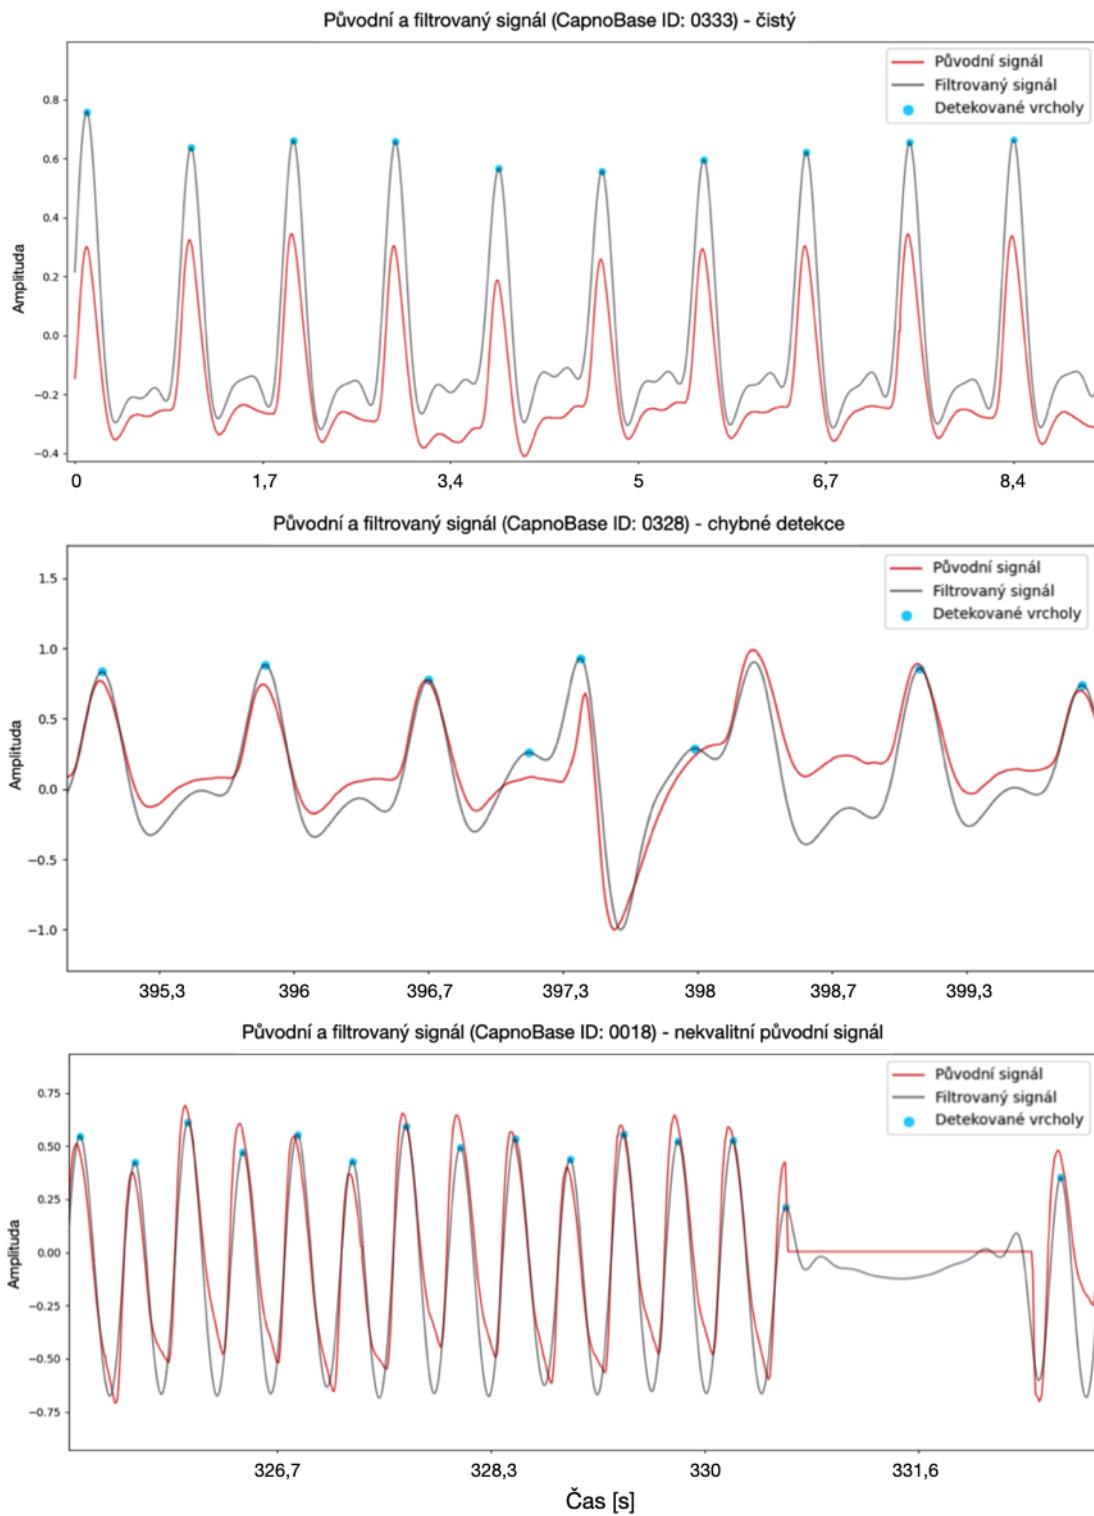
Z těchto intervalů jsme odvodili tepovou frekvenci pomocí vztahu popsaném rovnicí (5.2).

$$TF = \frac{60}{IBI_{median}} \quad (5.2)$$

Po volbě mezi průměrem, mediánem a modusem jsme se rozhodli pro medián. Na rozdíl od modusové a průměrné hodnoty byl medián nejméně citlivý na extrémní hodnoty. Na Obr. 5.3 vidíme, jak se může lišit průměr, modus a medián u signálů z našich databází.



Obr. 5.3: Stanovení TF z IBI pomocí průměru, mediánu a modusu.



Obr. 5.4: Ukázky zpracování signálů.

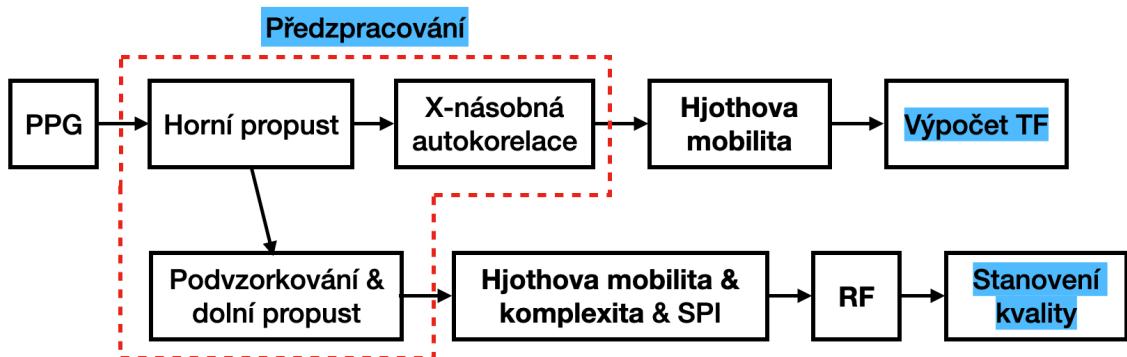
## 6 Využití Hjorthových deskriptorů na odhad TF a kvality signálů

V této kapitole je popsán alternativní přístup k odhadu srdeční tepové frekvence (TF) z fotopletysmografického signálu (PPG), využívající Hjorthovy deskriptory. Na rozdíl od standardních metod [4, 6, 14], které se opírají o detekci jednotlivých systolických vrcholů a výpočet IBI, využívá tento přístup frekvenční vlastnosti analyzovaného signálu. To je výhodou v případech, kdy je signál poškozen šumem, artefakty, nebo když je kladen důraz na výpočetní náročnost a rychlosť algoritmu.

V podkapitole 6.2 je popsán způsob využití Hjorthových deskriptorů pro odhad kvality signálu pomocí náhodného lesa (RF).

Hjorthovy deskriptory představují trojici příznaků určených z časového průběhu signálu, původně zavedených Hjorthem v roce 1970 pro kvantitativní popis elektroenzefalografických (EEG) signálů [15, 16]. Jedná se o *aktivitu* ( $H_0$ ), *mobilitu* ( $H_1$ ) a *komplexitu* ( $H_2$ ), které odrážejí střední výkon, střední úhlovou frekvenci a šířku pásma. Jejich výpočet vychází čistě z časové domény a nevyžaduje Fourierovu transformaci.

V dostupné literatuře jsme nenašli studie, které by Hjorthovy deskriptory využívaly k odhadu TF z PPG signálu. Proto v této práci navrhujeme a realizujeme nový přístup založený na Hjorthově *mobilitě* ( $H_1$ ). Tu počítáme na filtrovaných a několikanásobně autokorelovaných signálech. Struktura navrženého algoritmu je znázorněna na Obr. 6.1.



Obr. 6.1: Blokové schéma našeho využití Hjorthových deskriptorů.

### 6.1 Odhad TF pomocí Hjorthovy mobility

Jak již bylo uvedeno, Hjorthova *mobilita* ( $H_1$ ) představuje odhad střední (resp. dominantní) frekvence signálu v časové oblasti a to bez nutnosti výpočtu Fourierovy

transformace.

Načtení signálů z databází probíhá stejným způsobem jako u našeho prvního algoritmu, popsaného v podkapitole 5.1. Odlišný přístup jsme však zvolili při dělení signálů. Zatímco v předchozím algoritmu jsme signály z *CapnoBase* databáze dělili na minutové úseky, zde si můžeme ve vstupu funkce zvolit libovolný počet úseků, na které signál rozdělíme. Maximální počet těchto úseků odpovídá situaci, kdy jeden úsek trvá 10 s. Pokud zbyde po rozdělení signálu část, která je kratší než délka jednoho úseku, tak ji dále nezpracováváme. Je proto důležité zvolit takové dělení, které minimalizuje délku zahrozených úseků. Alternativou by bylo upravit algoritmus tak, aby zbylé části zpracoval samostatně nebo je přičlenil k předchozímu úseku. Tím bychom však porovnávali signály různých délek, což by mohlo výsledky zkreslit.

## Předzpracování

U analyzovaných signálů jsme provedli standardizaci. Nejprve jsme odstranili stejnosměrnou (DC) složku signálu, tedy jeho střední hodnotu  $\mu$ . Tento krok slouží k centrování signálu kolem nuly, čímž omezíme vliv DC složky na výpočet rozptylu signálu. Druhý krok standardizace je dělení signálu zbaveného hodnoty  $\mu$  jeho směrodatnou odchylkou  $\sigma$ . Rovnice pro standardizaci signálu je následující:

$$x[n] = \frac{x[n] - \mu}{\sigma}. \quad (6.1)$$

Následně byl signál filtrován Butterworthovým hornopropustným filtrem čtvrtého rádu s mezní frekvencí 0,5 Hz v obou směrech. Cílem této filtrace bylo potlačení respirační složky, přičemž prahová frekvence byla zvolena na základě předpokládané minimální hodnoty TF, jak je uvedeno v podkapitole 1.1.

Získaný signál byl dále sedmkrát za sebou autokorelován. Autokorelace je operace, při které se signál koreluje sám se sebou při různých časových posunech. Sedminásobná iterace byla zvolena na základě empirického pozorování výsledků na desetisekundových signálech z databáze CapnoBase. Cílem opakování autokorelace je zvýraznění dominantní periodické složky signálu. Klasická autokorelační funkce diskrétního signálu  $x[n]$  je definovaná jako:

$$r_x[m] = \sum_{n=0}^{N-m-1} x[n] \cdot x[n+m], \quad (6.2)$$

kde  $N$  je délka signálu a  $m$  je zpoždění. Výpočet probíhal ve frekvenční oblasti pomocí rychlé Fourierovy transformace, čímž se snížila výpočetní náročnost na  $O(i \cdot N \log N)$ , kde  $i$  je počet iterací autokorelace. Bez použití FFT by byla složitost  $O(N^2)$ .

Po každé iteraci autokorelace byl signál převeden do rozsahu  $[-1, 1]$  pomocí normalizace podle maximální absolutní hodnoty:

$$\hat{x}[n] = \frac{x[n]}{\max|x[n]|}. \quad (6.3)$$

Tato normalizace byla nezbytná, protože iterovaná autokorelace způsobuje exponenciální nárůst hodnot, což by vedlo k numerické nestabilitě a zkreslení výpočtu Hjorthových deskriptorů.

Opakovanou autokorelací dochází ke zvýšení spektrální ostrosti pro dominantní frekvenční složku, což jsme vyhodnotili jako žádoucí pro náš účel.

Porovnání spektra signálu před a po iterované autokorelací je znázorněno na Obr. 6.2. Horní část grafu zobrazuje časové průběhy původního, filtrovaného a autokorelovaného signálu, spodní část pak odpovídající spektra získaná pomocí rychlé Fourierovy transformace. Amplitudové spektrum bylo vypočteno výhradně pro účely vizualizace a nefiguruje v samotném výpočtu Hjorthových deskriptorů. Pro účely porovnání byla všechna spektra převedena na relativní jednotky pomocí normalizace vůči maximální hodnotě amplitudy daného signálu.

U běžných PPG signálu odpovídají periodické složky systolickým fázím, diastolickým fázím a respiračním složkám. Pro potlačení respiračních složek jsme použili hornopropustný filtr a pro potlačení složek diastolických fází jsme použili sedm iterací autokorelace.

## Výpočet TF z mobility

Po předzpracování signálu jsme vypočítali Hjorthovu mobilitu. Ta je definována [15, 18] jako druhá odmocnina poměru rozptylu první derivace signálu ku rozptylu signálu samotného:

$$H_1 = \sqrt{\frac{\text{var}(x[n] - x[n-1])}{\text{var}(x[n])}} = \sqrt{\frac{\text{var}(x')}{\text{var}(x)}} = \frac{\sigma_{x'}}{\sigma_x}. \quad (6.4)$$

Jelikož pracujeme v diskrétním prostředí, je derivace approximována první diferencí.

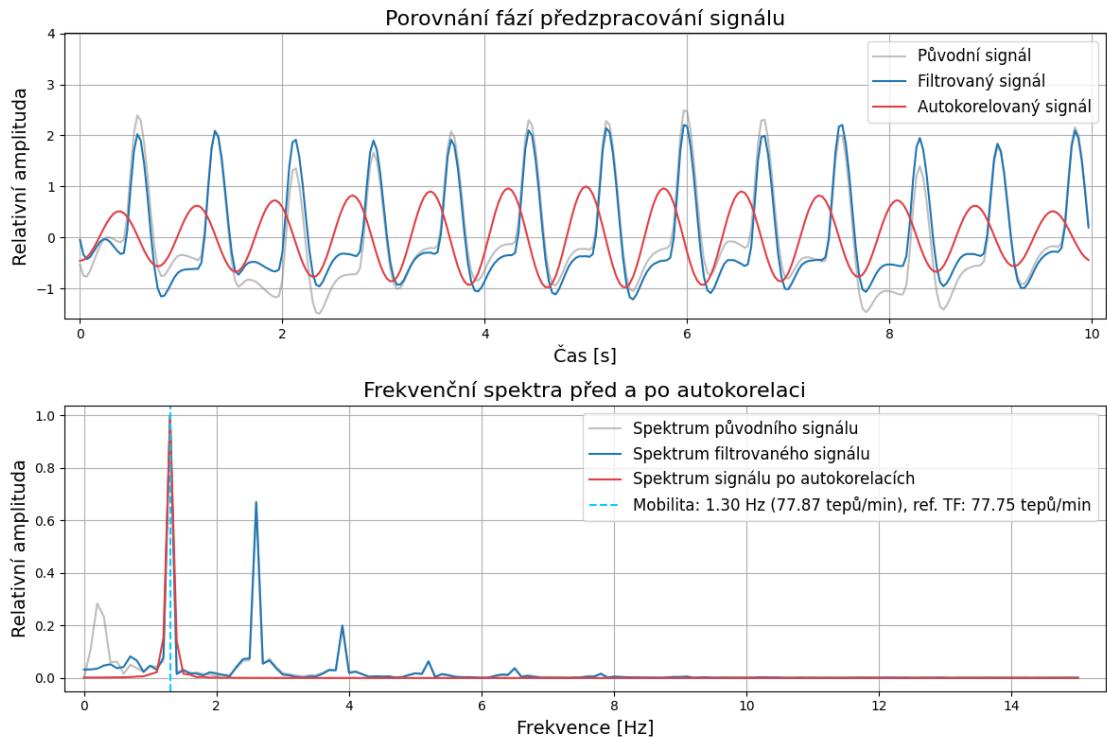
Rozptyl signálu  $x$  je dán vztahem:

$$\text{var}(x) = \frac{1}{N} \sum_{n=0}^{N-1} (x[n] - \mu)^2, \quad (6.5)$$

kde  $N$  je délka okna a  $\mu$  je střední hodnota signálu.

Podobně je definován i rozptyl první derivace signálu  $x'$ , přičemž první diferenci nelze definovat pro vzorek  $n = 0$ , takže součet začíná až od  $n = 1$ :

$$\text{var}(x') = \frac{1}{N-1} \sum_{n=1}^{N-1} (x'[n] - \mu')^2. \quad (6.6)$$



Obr. 6.2: Porovnání původního, filtrovaného a autokorelovaného signálu.

Z hodnoty  $H_1$  jsme následně odvodili dominantní frekvenci  $f_{dom}$  [Hz], kterou jsme vynásobili šedesáti, abychom dostali odpovídající hodnotu TF v tepech za minutu:

$$TF_{Hjorth} = 60 \cdot f_{dom} = \frac{60 \cdot H_1}{2\pi}. \quad (6.7)$$

Hodnota dominantní frekvence je graficky znázorněna i písemně zmíněna na Obr. 6.2 společně s odpovídající tepovou frekvencí a referenční hodnotou TF z databáze.

Přestože mají klasické metody detekce vrcholů [13] lineární průchod signálem s asymptotickou složitostí  $O(N)$ , jejich praktická složitost může být vyšší kvůli víceprůchodovým algoritmům, adaptivním prahům, filtrováním nebo nastavování bloků zájmu (popsané v podkapitole 4.3).

Naopak výpočet Hjorthovy mobility má sice po  $i$  iteracích autokorelace (prováděné pomocí FFT) složitost  $O(i \cdot N \log N)$ , avšak díky své jednoduchosti a absenci větvení může být v praxi rychlejší.

Výsledky odhadu TF na základě Hjorthovy mobility jsou diskutovány v kapitole 7, přičemž porovnání rychlosti exekuce algoritmů je uvedeno v Tab. 7.1.

## 6.2 Hodnocení kvality PPG signálů

Tato podkapitola popisuje metodu automatického hodnocení kvality PPG signálů pomocí Hjorthových deskriptorů s využitím klasifikátoru typu „náhodný les“ (RF). Cílem této analýzy je ověřit, zda kombinace mobility, komplexity a indexu spektrální čistoty (SPI), postačuje k automatické binární klasifikaci PPG signálů na základě jejich kvality definované referenčním algoritmem od Orphanidou z knihovny NeuroKit2 [14].

### Segmentace a předzpracování signálů

Klasifikátor byl trénován na signálech ze dvou databází: CapnoBase a BUT PPG, jejichž záznamy se liší délkou, jak podrobněji popisujeme v kapitole 3.

Pro zajištění srovnatelnosti Hjorthových deskriptorů mezi oběma databázemi byly signály z CapnoBase rozděleny na nepřekrývající se segmenty o délce 10 s, což odpovídá délce jednotlivých záznamů v databázi BUT PPG. Tato segmentace zároveň přispívá ke konzistenci vstupních dat a zvyšuje přesnost rozhodování jednotlivých stromů klasifikátoru.

Následně byly signály z CapnoBase převzorkovány na vzorkovací frekvenci 30 Hz, aby odpovídaly frekvenci signálů z databáze BUT PPG. Převzorkování bylo realizováno pomocí funkce `resample` z knihovny `scipy`, která implementuje Fourierovu interpolaci. Jelikož tato metoda neobsahuje předběžnou dolnofrekvenční filtraci, mohlo by při přítomnosti vyšších frekvenčních složek dojít k aliasingu.

Abychom tomuto jevu předešli, aplikovali jsme před převzorkováním dolnopropustný filtr typu Butterworth čtvrtého rádu s mezní frekvencí 14 Hz. Tím jsme potlačili složky nad polovinou cílové vzorkovací frekvence a zachovali pouze spektrum relevantní pro analýzu srdeční činnosti.

Po sjednocení délky a vzorkovací frekvence byly všechny signály standardizovány viz (6.1). V souladu s postupem uvedeným v podkapitole 6.1 jsme dále odstranili nízkofrekvenční složky pod 0,5 Hz. Zde jsme navíc potlačili i složky nad 3,35 Hz (201 tepům za minutu), čímž jsme omezili spektrum pouze na fyziologicky očekávané rozsahy srdeční frekvence.

### Výpočet příznaků pro náhodný les

První dva příznaky odpovídají Hjorthovým deskriptorům, přičemž mobilita ( $H_1$ ) již byla popsána v předchozí podkapitole rovnicí (6.4).

Druhý příznak, Hjorthova komplexita ( $H_2$ ), kvantifikuje míru toho, jak se signál v čase odchyluje od harmonického průběhu. Je definována jako poměr mobility první

derivace signálu ku mobilitě samotného signálu [15, 18]:

$$H_2 = \sqrt{\frac{H_1(x')}{H_1(x)}} = \sqrt{\frac{\text{var}(x'')/\text{var}(x')}{\text{var}(x')/\text{var}(x)}} = \frac{\sigma_{x''} \cdot \sigma_x}{\sigma_{x'}^2} [-], \quad (6.8)$$

kde  $x$ ,  $x'$ ,  $x''$  jsou signál, jeho první derivace a jeho druhá derivace.  $\sigma_x$  označuje směrodatnou odchylku. Pro čistě harmonický signál, jako je sinusoida, by vycházelo  $H_2 = 1$ . S rostoucím podílem vyšších frekvenčních složek se však signál stává proměnlivějším, a tím vyšší je hodnota  $H_2$ .

Hjorthova komplexita tak slouží jako bezrozměrný ukazatel nepravidelnosti signálu např. při automatickém hodnocení kvality EEG signálů [18].

Třetím příznakem je index spektrální čistoty (SPI), který je definován jako převrácená hodnota komplexity:

$$SPI = \frac{1}{H_2} = \frac{\sigma_{x'}^2}{\sigma_{x''} \cdot \sigma_x} [-]. \quad (6.9)$$

Všechny tři příznaky jsou standardizovány pomocí funkce `StandardScaler`, aby byl zajištěn jejich jednotný váhový vliv při klasifikaci.

## Náhodný les

Pro odhad kvality signálů jsme použili již zmíněný klasifikátor *náhodný les* (RF), který tvoří sadu rozhodovacích stromů a kombinuje jejich výstupy hlasováním. Na rozdíl od lineárních modelů dokáže zachytit i nelineární vztahy mezi příznaky.

Použili jsme implementaci `RandomForestClassifier` z knihovny `scikit-learn` s výchozími parametry: `n_estimators` = 150 (počet stromů), `max_depth` = 7 (maximální hloubka stromu) a `max_features` = `sqrt` (pro každý uzel se testuje náhodně vybraná odmocnina z celkového počtu příznaků). Optimalizace těchto parametrů byla provedena pomocí metody `GridSearchCV` ze stejné knihovny, která systematicky vybírá nejlepší kombinace z námi předdefinovaných hodnot parametrů. Pro zajištění deterministického chování jsme parametr náhodné inicializace nastavili na hodnotu `random_state` = 42.

Rozdělení datasetu do trénovací a testovací množiny proběhlo v poměru 60 % ku 40 %, přičemž jsme použili stratifikaci, abychom zachovali poměr tříd (kvalitní/nekvalitní signály). Jelikož datová sada vykazovala nevyváženosť tříd, aktivovali jsme parametr `class_weight='balanced'`, který upravuje váhy jednotlivých tříd podle jejich četnosti. To zajišťuje, že model nebude preferovat většinovou třídu, ať už kvalitní nebo nekvalitní.

Jednou z výhod RF je možnost kvantifikovat důležitost jednotlivých příznaků na základě jejich vlivu na rozhodování stromů, což přispívá k interpretovatelnosti modelu a transparentnosti výsledků.

Výkonnost modelu jsme hodnotili pomocí pětinásobného křížového ověření, což umožňuje stabilní odhad generalizační chyby bez závislosti na konkrétním rozdělení dat. Jako hlavní metriku jsme zvolili  $F_1$  skóre, které je definované jako harmonický průměr mezi přesností (PPV) a citlivostí (Se).

Výstupem modelu je pravděpodobnostní binární skóre kvality signálů. To lze interpretovat jako hlasování lesa o každém testovaném signálu, zde je daný signál kvalitní nebo ne.

## Referenční hodnota kvality

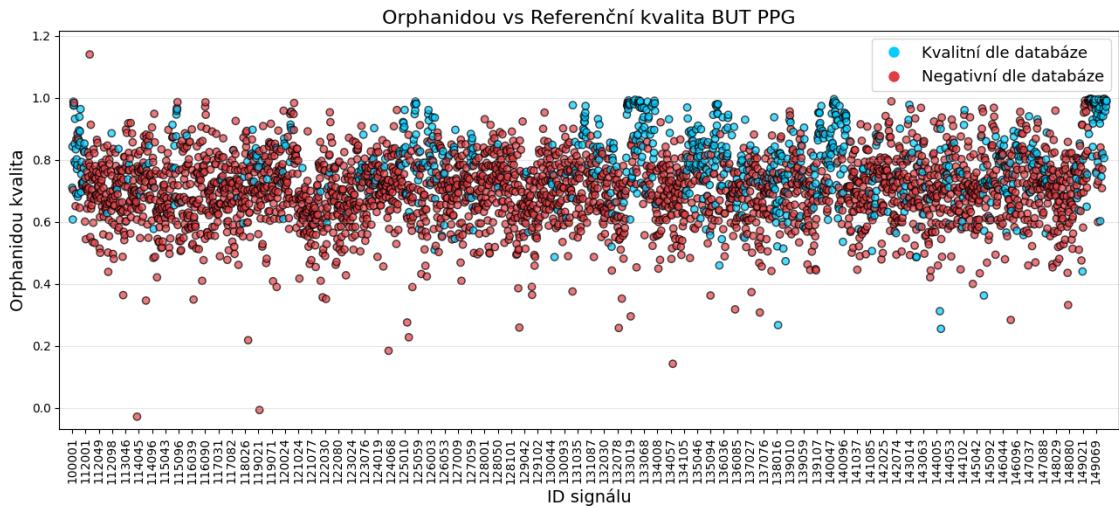
Databáze BUT PPG [1, 2] poskytuje binární anotace kvality signálu založené na schopnosti odhadnout tepovou frekvenci z PPG signálu. Ten je označen jako kvalitní, pokud alespoň tři z pěti expertů určili TF s chybou menší nebo rovnou 5 tepů za minutu vůči referenci z EKG. Hodnocení je však závislé na lidském úsudku i použitém softwaru.

Pro trénink a evaluaci algoritmů na obou databázích jsme se rozhodli použít odlišné referenční hodnoty kvality. Pro jejich výpočet jsme zvolili algoritmus dle Orphanidou [9, 14]. Ten vyhodnocuje kvalitu signálu pomocí kombinace pravidel založených na detekci pulzů a následného porovnání morfologie jednotlivých pulzních vln s průměrnou šablonou. Byl převzat z knihovny **NeuroKit2** [14], která vrací spojité skóre v rozsahu  $<0,1>$ , založené na průměrné korelací mezi jednotlivými pulzy a vytvořenou šablonou. Jako prahovou hodnotu pro binární klasifikaci jsme zvolili hodnotu 0,9, což odpovídá vysoké kvalitě signálu.

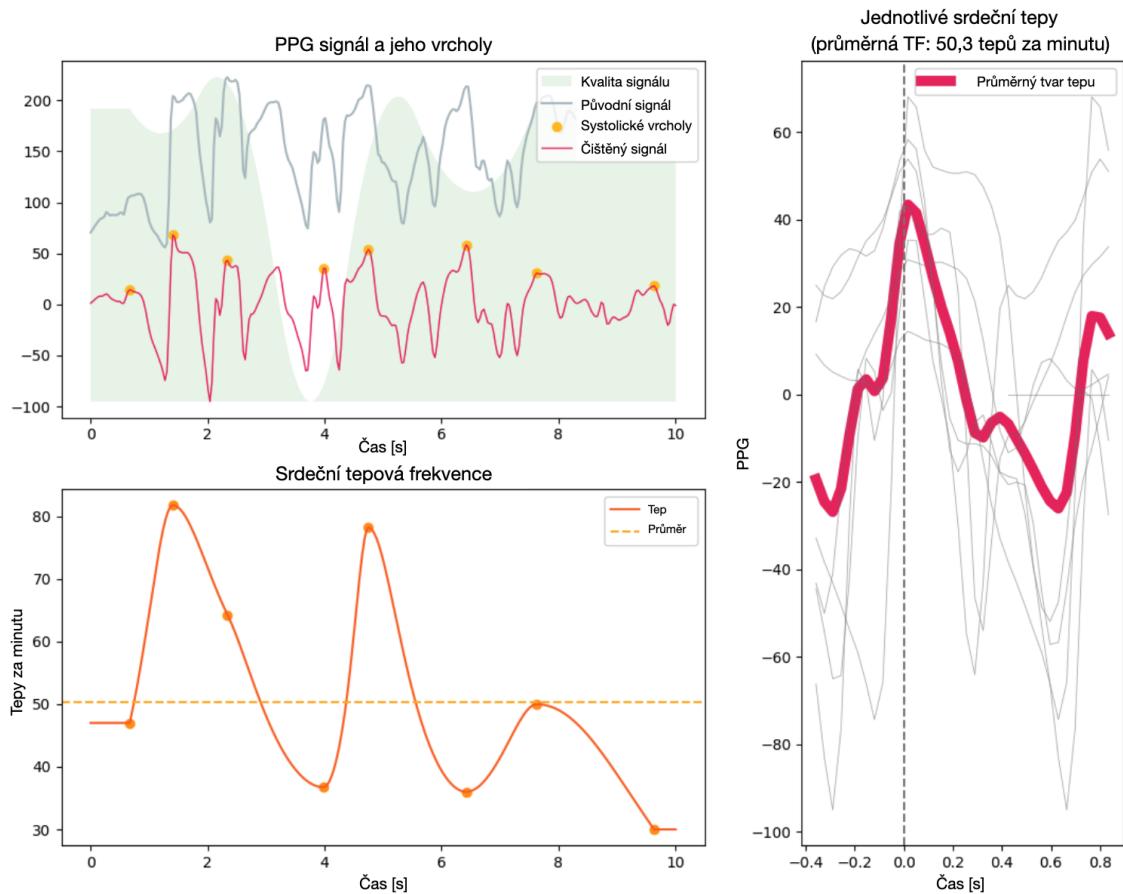
Obr. 6.3 ukazuje rozptyl skóre kvality dle Orphanidou pro celou BUT PPG databázi a jejich vztah k binární anotaci. Je patrné, že se hodnoty kvalit neshodují. Např. Obr. 6.4 zobrazuje jeden ze signálů, který byl experty označen jako kvalitní, ale hodnota kvality dle Orphanidou je přibližně 0,59. Chyba referenčního odhadu TF je u tohoto signálu 26 tepů za minutu.

Z těchto důvodů považujeme skóre podle Orphanidou za vhodnější základ pro trénink modelu automatického hodnocení kvality PPG signálu.

Úspěšnost algoritmů odhadující TF budeme hodnotit pomocí obou referenčních hodnot kvality. Výsledky těchto algoritmů budou diskutovány v kapitole 7.



Obr. 6.3: Porovnání kvality dle Orphanidou a referenční anotace z databáze BUT PPG.



Obr. 6.4: Příklad signálu označeného jako kvalitní, přestože obsahuje silné artefakty a vykazuje vysokou chybu odhadu TF.

# 7 Výsledky

Tato kapitola obsahuje výsledky odhadu tepové frekvence z fotopletysmografických signálů pomocí tří různých metod: referenčního Elgendiho algoritmu, vlastního algoritmu založeného na detekci systolických vrcholů a nově navržené metody využívající Hjorthovy deskriptory.

Výsledky jsou vyhodnoceny samostatně pro obě použité databáze: CapnoBase a Brno University of Technology Smartphone PPG Database. Výsledky automatického posouzení kvality signálů jsou shrnutы v podkapitole 7.3.

## 7.1 Výsledky pro databázi CapnoBase

U této databáze máme k dispozici referenční hodnoty systolických vrcholů, a proto můžeme použít statistické metody pro vyhodnocení kvality detekce, jako je citlivost ( $Se$ ), pozitivní prediktivní hodnota (PPV) a F1 skóre. Citlivost vyjadřuje procento vrcholů, které použitý algoritmus správně rozpoznal z celkového počtu *referenčních* vrcholů:

$$Se = \frac{TP}{TP + FN} \cdot 100\%. \quad (7.1)$$

Vyšší citlivost znamená nižší riziko, že algoritmus opomene detektovat skutečný vrchol.

Pozitivní prediktivní hodnota vyjadřuje procento vrcholů, které vybraný algoritmus určil správně z celkového počtu *detekovaných* vrcholů:

$$PPV = \frac{TP}{TP + FP} \cdot 100\%. \quad (7.2)$$

Vyšší hodnota PPV znamená, že algoritmus detekuje méně falešných vrcholů.

F1 skóre je harmonický průměr citlivosti a PPV vyjádřen v procentech:

$$F1 = 2 \cdot \frac{Se \cdot PPV}{Se + PPV} \cdot 100\%. \quad (7.3)$$

Tyto metriky počítáme pouze pro Elgendiho algoritmus a vlastní algoritmus detekce vrcholů, kvůli povaze algoritmu využívajícího Hjorthovu mobilitu, který neprovádí detekci vrcholů, ale přímo odhaduje tepovou frekvenci. Když jsme je ale počítali, nastavili jsme toleranční pásmo pro výpočet matice záměn na  $\pm 0,1$  s, které nám definuje, jak daleko od referenčního vrcholu se může detekovaný vrchol nacházet, aby byl považován za správně detekovaný. V Tab. 7.1 jsou hodnoty  $Se$  a  $PPV$  vypočítány ze součtu všech  $TP$ ,  $FP$  a  $FN$ . F1 skóre je pak vypočítáno z těchto hodnot.

Dále jsme vyhodnotili průměrnou absolutní chybu (MAE) mezi referenční a odhadovanou tepovou frekvencí dle rovnice (7.4).

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |TF_{i,ref} - TF_{i,est}| \quad (7.4)$$

Jako dodatečné kritérium jsme stanovili poměr mezi dobře a špatně odhadnutými signály. Za dobře odhadnuté byly považovány signály s MAE menší než 5 bpm, což odpovídá prahové hodnotě dle mezinárodního standardu IEC 60601-2-27 a metodice databáze BUT PPG [1]. V tabulce používáme označení „d:s“ pro poměr „dobře:špatně“ odhadnutých signálů.

Poslední sledovanou metrikou byla výpočetní náročnost jednotlivých algoritmů, vyjádřená jako celkový čas potřebný ke zpracování celé databáze CapnoBase. Výpočty probíhaly na platformě Apple M1. Hodnoty jsou orientační a slouží pouze k vzájemnému srovnání mezi algoritmy. Vzhledem k rozdílným charakteristikám databází (odlišná vzorkovací frekvence, délka i počet signálů, datový formát) nejsou časy mezi CapnoBase a BUT PPG přímo srovnatelné.

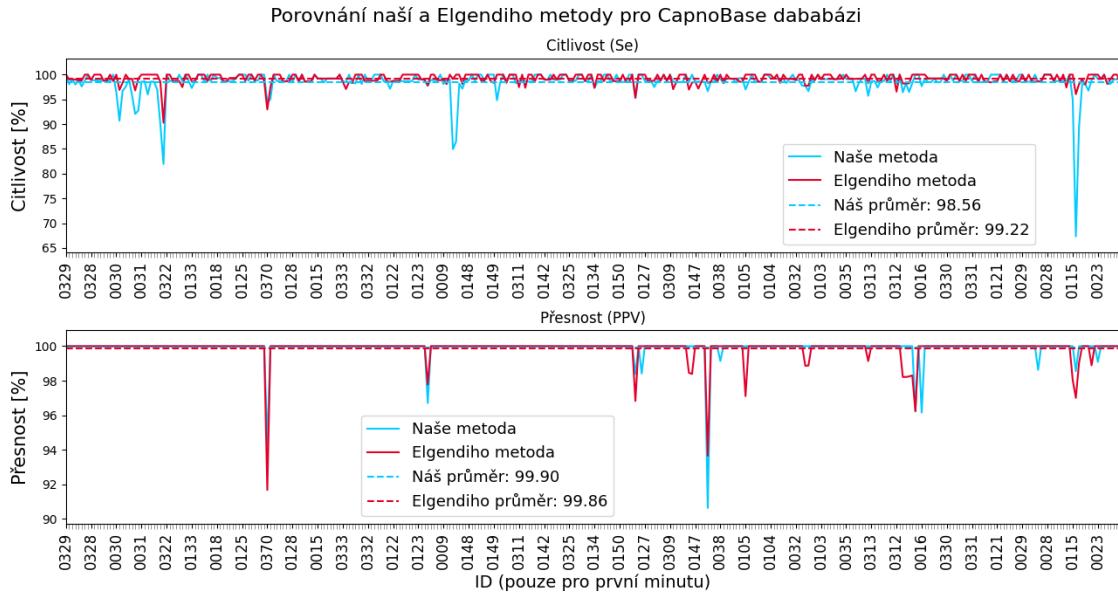
Metriky přesnosti pro všechny tři algoritmy jsou uvedeny v Tab. 7.1, a to vždy pro různé délky vstupního signálu.

Tab. 7.1: Srovnání metod odhadu TF.

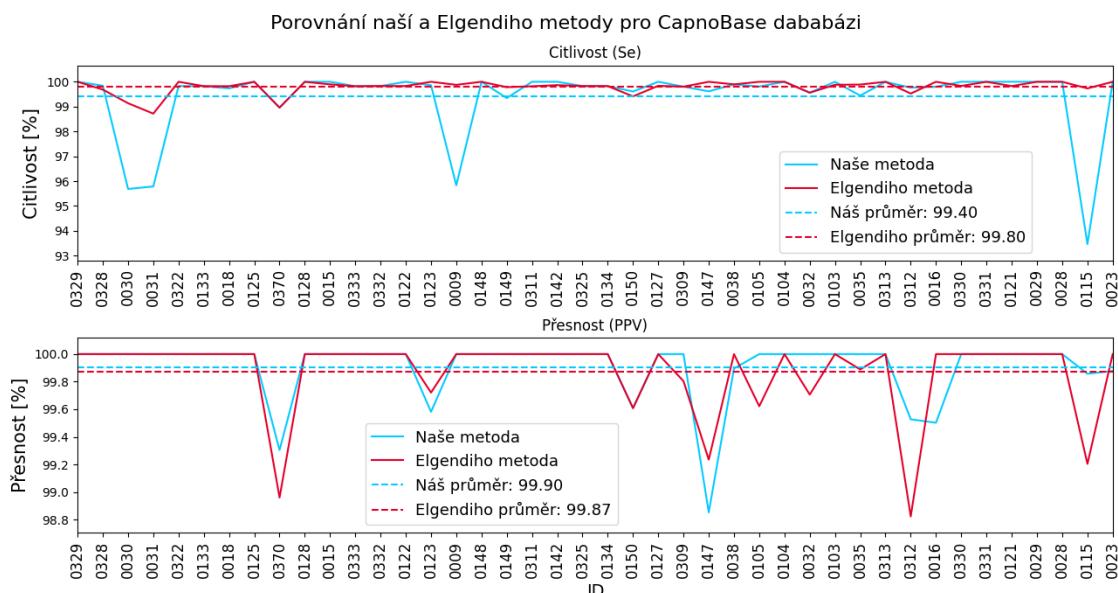
<b>Metoda</b> (délka [s])	<b>Se</b> [%]	<b>PPV</b> [%]	<b>F1</b> [%]	<b>MAE</b> [bpm]	<b>Poměr</b> [d:s]	<b>Čas</b> [s]
Elgendi (480)	99,81	99,89	99,85	0,31	42:0	16,1
Elgendi (62,5)	99,23	99,88	99,55	0,35	336:0	17,9
Vlastní vrcholová detekce (480)	99,34	99,91	99,63	0,31	42:0	2,4
Vlastní vrcholová detekce (62,5)	98,49	99,91	99,20	0,37	336:0	2,7
Hjorth (480)	—	—	—	1,52	40:2	2,6
Hjorth (60)	—	—	—	0,80	332:4	2,7
Hjorth (10)	—	—	—	0,61	2015:1	14,5

Na Obr. 7.1 a Obr. 7.2 je znázorněno srovnání citlivosti a přesnosti mezi vlastní metodou detekce vrcholů a referenční Elgendiho metodou. První obrázek zobrazuje výsledky pro minutové úseky (přeněji 62,5 s), zatímco druhý shrnuje výstupy pro celé osmiminutové záznamy. Nejnižší hodnotu citlivosti vykazuje náš algoritmus ve druhé minutě signálu 0115, což odpovídá případu zobrazenému na Obr. 7.3.

Je důležité poznamenat, že zobrazené hodnoty Se a PPV se v grafech liší od hodnot uvedených v Tab. 7.1. V tabulce jsou hodnoty vypočteny jako agregovaná



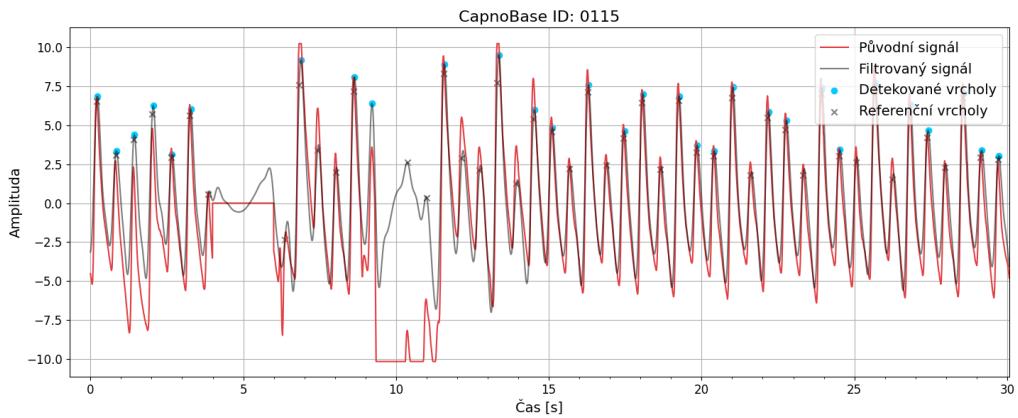
Obr. 7.1: Srovnání metod detekující vrcholy pro minutové úseky.



Obr. 7.2: Srovnání metod detekující vrcholy celý signál.

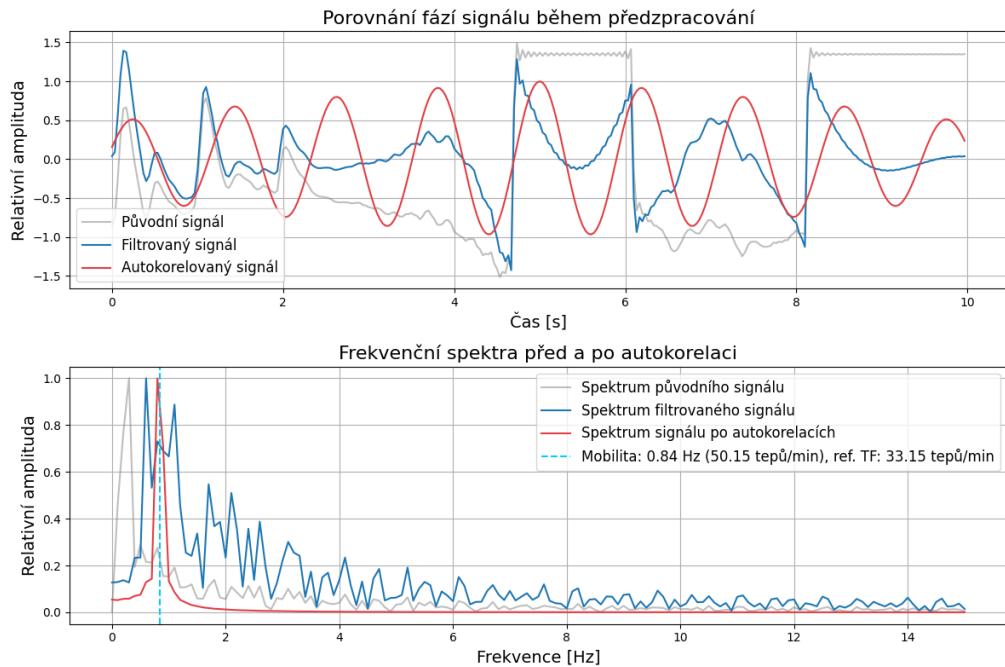
hodnota pro celou databází (tj. globální součet všech TP, FP a FN). Na druhou stranu, v grafech jsou vypočítané hodnoty Se a PPV individuálně a z těch je následně vypočítán a vykreslen průměr. Tento přístup lépe odpovídá srovnání výkonnosti napříč jednotlivými záznamy, zatímco tabulková metrika lépe charakterizuje celkový výkon algoritmů.

Bland-Altmanovy grafy znázorněné na Obr. 7.5 porovnávají rozdíl mezi odha-



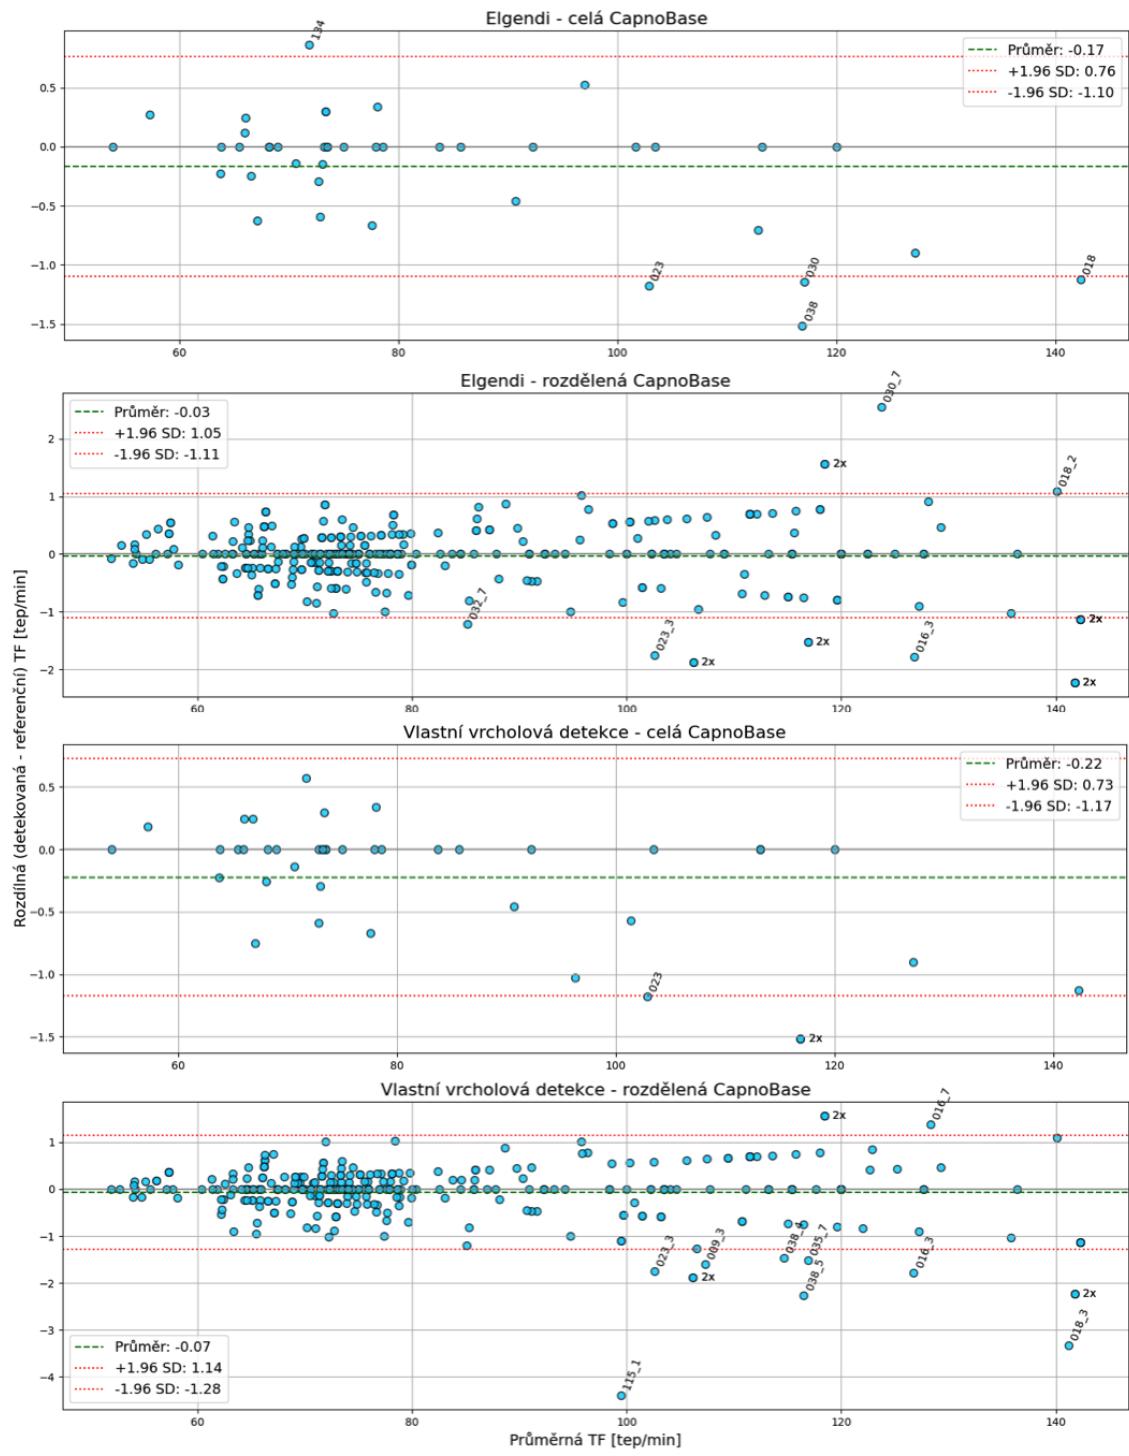
Obr. 7.3: Chybný odhad TF pomocí vlastní vrcholové detekce.

dovanou a referenční tepovou frekvencí pro obě metody detekce vrcholů. Výsledky jsou rozděleny nejen podle použité metody (vlastní versus Elgendi), ale také podle délky analyzovaných úseků – zvlášť pro celé osmiminutové signály a zvlášť pro jejich 62,5 s dlouhé úseky. V grafech jsou vyznačeny průměrné odchylky (ME) jako zelená přerušovaná čára, zatímco hranice shody, definované jako  $\pm 1,96 \cdot SD$ , jsou znázorněny červenými přerušovanými čarami. Tato rozdílová analýza umožňuje posoudit, jak výrazně se odhady liší od referenčních hodnot a zda je chyba závislá na velikosti tepové frekvence.

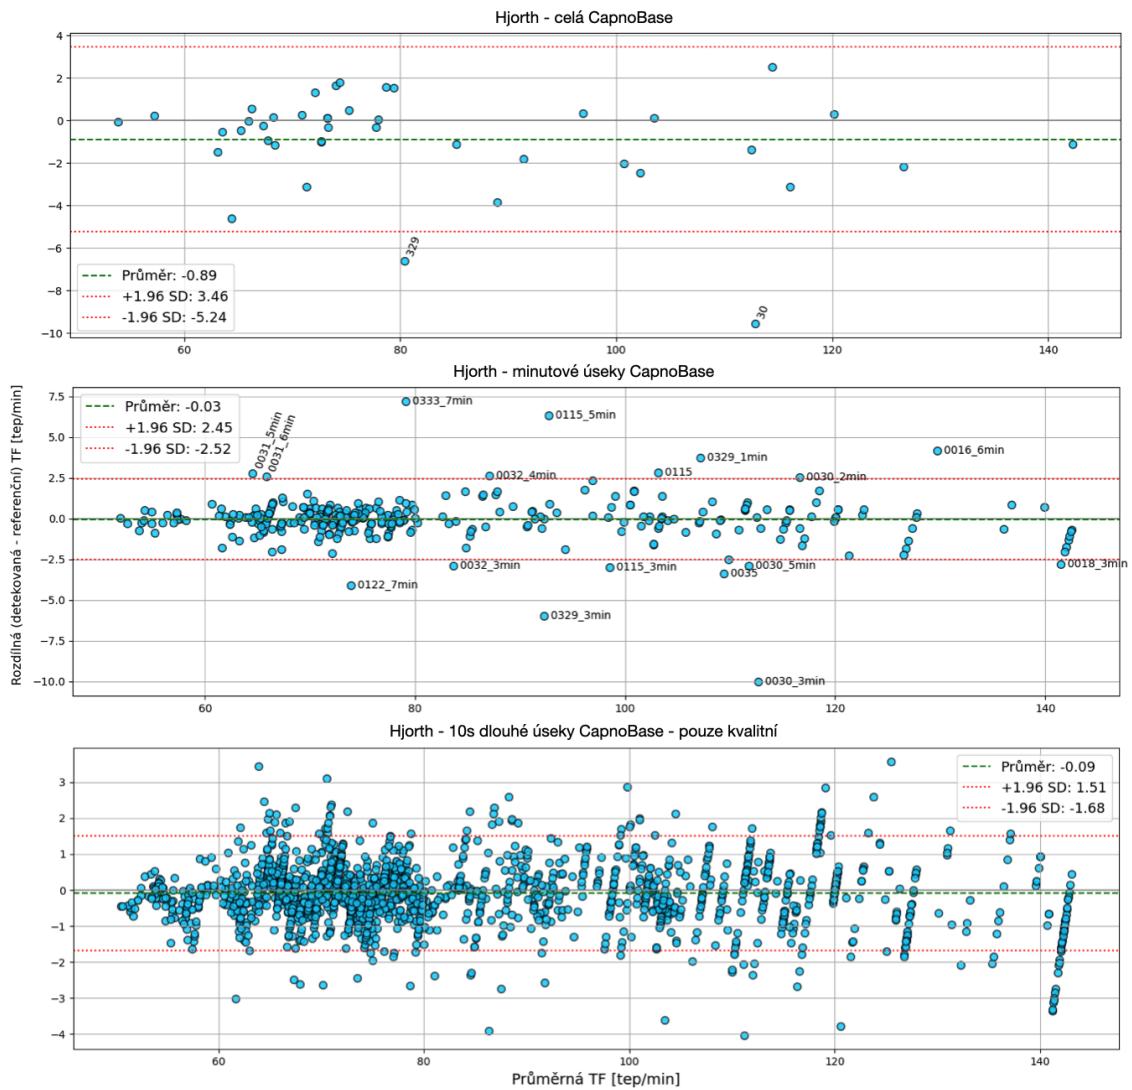


Obr. 7.4: Chybný odhad TF pomocí Hjorthových deskriptorů u nekvalitního signálu.

Obr. 7.6 zachycuje výsledky Bland-Altmanovy analýzy pro metodu využívající Hjorthovy deskriptory. Grafy jsou opět rozděleny dle délky analyzovaných úseků: horní pro celé signály, prostřední pro minutové segmenty a spodní pro desetisekundové úseky. V posledním grafu byly zahrnuty pouze signály označené jako kvalitní, čímž byl vyloučen jeden extrémně odlehлý případ (signál 0147, 25. minuta), který by vzhledem ke své vysoké chybě narušil škálu zobrazení. Tento úsek je detailně zachycen na obrázku 7.4, kde je patrná výrazná deformace signálu a posun dominantní frekvence. Společně s ním bylo vyloučeno dalších 15 signálů.



Obr. 7.5: Bland-Altmanova analýza pro metody detekující vrcholy.



Obr. 7.6: Bland-Altmanova analýza pro metodu využívající Hjorthovy deskriptory.

## 7.2 Výsledky pro databázi BUT PPG

Tab. 7.2: Srovnání metod odhadu TF.

Metoda (délka [s])	Se [%]	PPV [%]	F1 [%]	MAE [bpm]	Poměr [d:š]	MAE [bpm]	Čas [s]
Elgendi (480)	99,81	99,89	99,85	0,31	42:0	16,1	6
Elgendi (62,5)	99,23	99,88	99,55	0,35	336:0	17,9	1
Vlastní vrcholová detekce (480)	99,34	99,91	99,63	0,31	42:0	2,4	2
Vlastní vrcholová detekce (62,5)	98,49	99,91	99,20	0,37	336:0	2,7	1
Hjorth (480)	–	–	–	1,52	40:2	2,6	1
Hjorth (60)	–	–	–	0,80	332:4	2,7	6
Hjorth (10)	–	–	–	0,61	2015:1	14,5	6

## 7.3 Výsledky automatického posouzení kvality

## **8 Diskuze**

Z grafů je patrné, že až na několik málo odchylek u jednotlivých signálů dosahují obě metody v průměru vysokých hodnot Se i PPV.

Na Obr. 7.3 došlo k selhání detekce z důvodu přítomnosti silné respirační vlny.



# Závěr

Tato bakalářská práce se zaměřila na odhad tepové frekvence (TF) z fotopletysmografických (PPG) signálů. Cílem bylo jednak poskytnout stručný přehled existujících metod pro odhad TF z PPG signálů, jednak navrhnout a popsat algoritmy pro spolehlivé stanovení tepové frekvence.

V teoretické části byla popsána fotopletysmografie jako neinvazivní optická metoda monitorování změn objemu krve v tkáních, která se používá zejména pro sledování kardiovaskulárních parametrů. Byly představeny základní principy PPG signálů a faktory, které mohou ovlivnit jejich kvalitu a přesnost měření.

Praktická část práce se soustředila na implementaci a testování několika algoritmů pro detekci systolických vrcholů v PPG signálech, včetně Aboyova algoritmu, jeho vylepšené verze Aboy++, Elgendiho algoritmu, Rezonátoru s nulovou frekvencí (ZFR) a nově navrženého Upraveného Aboyova algoritmu. Algoritmy byly testovány na dvou databázích: CapnoBase a BUT PPG.

Výsledky ukázaly, že Rezonátor s nulovou frekvencí (ZFR) dosahuje nejlepších výsledků na databázi CapnoBase, přičemž vykazuje vysokou citlivost a pozitivní prediktivní hodnotu. Elgendiho algoritmus se prokázal jako nejspolehlivější na databázi BUT PPG, přičemž dosahoval nejnižší průměrné odchylinky mezi detekovanou a referenční TF.

Jedním z klíčových cílů této práce byl vývoj a implementace upraveného Aboyova algoritmu. Tento algoritmus dosahuje lepších odhadů TF na databázi CapnoBase ve srovnání s původní verzí, a to zejména díky zjednodušení a odstranění některých kroků, které způsobovaly přehlížení skutečných systolických vrcholů. Na databázi BUT PPG však vykazoval vyšší odchylinky TF, což naznačuje potřebu další optimalizace pro spolehlivější detekci.

Dalším krokem pro zlepšení přesnosti odhadu TF by mohlo být využití pokročilejších technik strojového učení a hlubokých neuronových sítí, které mohou nabídnout lepší adaptaci na různé typy signálů a zlepšit robustnost algoritmů vůči šumu a artefaktům.



# Literatura

- [1] NEMCOVA, Andrea, Enikö VARGOVA, Radovan SMISEK, Lucie MARSA-NOVA, Lukas SMITAL, Martin VITEK a Mihajlo JAKOVLJEVIC. Brno University of Technology Smartphone PPG Database (BUT PPG): Annotated Dataset for PPG Quality Assessment and Heart Rate Estimation. *BioMed Research International* [online]. 2021-09-06, 2021, 1-6 [cit. 2024-05-23]. ISSN 2314-6141. Dostupné z: <https://doi.org/10.1155/2021/3453007>
- [2] Nemcova, A., Smisek, R., Vargova, E., Maršánová, L., Vitek, M., Smital, L., Filipenska, M., Sikorova, P., a Gálík, P. Brno University of Technology Smartphone PPG Database (BUT PPG) (version 2.0.0). PhysioNet. 2024 [cit. 2025-03-23]. Dostupné z: <https://doi.org/10.13026/tn53-8153>
- [3] KARLEN, Walter. CapnoBase IEEE TBME Respiratory Rate Benchmark. *Borealis* [online]. 2021 [cit. 2024-05-23]. Dostupné z: <https://doi.org/10.5683/SP2/NLB8IT>
- [4] VARGOVÁ, Enikö. Stanovení kvality a odhad tepové frekvence ze signálu PPG [online]. Brno, 2021 [cit. 2022-11-15]. Dostupné z: <https://www.vutbr.cz/studenti/zav-prace/detail/134388>. Bakalářská práce. Vysoké učení technické v Brně, Fakulta elektrotechniky a komunikačních technologií, Ústav biomedicínského inženýrství. Vedoucí práce Andrea Němcová.
- [5] SIDDIQUI, Sarah Ali, Yuan ZHANG, Zhiquan FENG a Anton KOS. A Pulse Rate Estimation Algorithm Using PPG and Smartphone Camera. *Journal of Medical Systems* [online]. 2016, 40(5) [cit. 2024-05-20]. ISSN 0148-5598. Dostupné z: <https://doi.org/10.1007/s10916-016-0485-6>
- [6] CHARLTON, Peter H, Kevin KOTZEN, Elisa MEJÍA-MEJÍA, et al. Detecting beats in the photoplethysmogram: benchmarking open-source algorithms. *Physiological Measurement* [online]. 2022-08-19, 43(8) [cit. 2024-05-20]. ISSN 0967-3334. Dostupné z: <https://doi.org/10.1088/1361-6579/ac826d>
- [7] CHARLTON, Peter H, John ALLEN, Raquel BAILÓN, et al. The 2023 wearable photoplethysmography roadmap. *Physiological Measurement* [online]. 2023-11-29, 44(11) [cit. 2024-05-20]. ISSN 0967-3334. Dostupné z: <https://doi.org/10.1088/1361-6579/acead2>
- [8] KARLEN, Walter, S. RAMAN, J. M. ANSERMINO a G. A. DUMONT. Multi-parameter Respiratory Rate Estimation From the Photoplethysmogram. *IEEE Transactions on Biomedical Engineering* [online]. 2013, 60(7), 1946-1953 [cit.

2024-04-16]. ISSN 0018-9294. Dostupné z: <https://doi.org/10.1109/TBME.2013.2246160>

- [9] ORPHANIDOU, Christina, Timothy BONNICI, Peter CHARLTON, David CLIFTON, David VALLANCE a Lionel TARASSENKO. Signal-Quality Indices for the Electrocardiogram and Photoplethysmogram: Derivation and Applications to Wireless Monitoring. *IEEE Journal of Biomedical and Health Informatics* [online]. 2015, (3), 832-838 [cit. 2025-04-20]. Dostupné z: <https://doi.org/10.1109/JBHI.2014.2338351>
- [10] ORPHANIDOU, Christina. *Signal Quality Assessment in Physiological Monitoring* [online]. Cham: Springer International Publishing, 2018 [cit. 2024-05-20]. SpringerBriefs in Bioengineering. ISBN 978-3-319-68414-7. Dostupné z: <https://doi.org/10.1007/978-3-319-68415-4>
- [11] GODA, Márton Á, Peter H CHARLTON a Joachim A BEHAR. pyPPG: A Python toolbox for comprehensive photoplethysmography signal analysis. *Physiological Measurement* [online]. 2024-04-08, 45(4) [cit. 2024-05-20]. ISSN 0967-3334. Dostupné z: <https://doi.org/10.1088/1361-6579/ad33a2>
- [12] PŘIBIL, Jiří, Anna PŘIBILOVÁ a Ivan FROLLO. Analysis of Heart Pulse Transmission Parameters Determined from Multi-Channel PPG Signals Acquired by a Wearable Optical Sensor. *Measurement Science Review* [online]. 2023, 23, 217-226 [cit. 2025-2-20]. Dostupné z: <https://api.semanticscholar.org/CorpusID:264289667>
- [13] ELGENDI, Mohamed, Ian NORTON, Matt BREARLEY, Derek ABBOTT, Dale SCHUURMANS a Vladimir E. BONDARENKO. Systolic Peak Detection in Acceleration Photoplethysmograms Measured from Emergency Responders in Tropical Conditions. *PLoS ONE* [online]. 2013-10-22, 8(10) [cit. 2024-05-20]. ISSN 1932-6203. Dostupné z: <https://doi.org/10.1371/journal.pone.0076585>
- [14] MAKOWSKI, Dominique, Tam Pham, Zuo Jia Lau, et al. NeuroKit2: A Python toolbox for neurophysiological signal processing. *Behavior Research Methods* [online]. 2021, 53, 1689–1696 [cit. 2024-05-20]. ISSN 1554-3528. Dostupné z: <https://doi.org/10.3758/s13428-020-01516-y>
- [15] HJORTH, Bo. EEG analysis based on time domain properties. *Electroencephalography and Clinical Neurophysiology* [online]. 1970, 29, 306-310 [cit. 2025-04-23]. Dostupné z: [https://doi.org/10.1016/0013-4694\(70\)90143-4](https://doi.org/10.1016/0013-4694(70)90143-4)

- [16] HJORTH, Bo. The physical significance of time domain descriptors in EEG analysis. *Electroencephalography and Clinical Neurophysiology* [online]. 1973, 34(3), 321-325 [cit. 2025-04-14]. ISSN 00134694. Dostupné z: [https://doi.org/10.1016/0013-4694\(73\)90260-5](https://doi.org/10.1016/0013-4694(73)90260-5)
- [17] PERALTA, Elena, Jesus LAZARO, Eduardo GIL, Raquel BAILÓN a Vaidotas MAROZAS. Robust Pulse Rate Variability Analysis from Reflection and Transmission Photoplethysmographic Signals [online]. 2017-09-14, - [cit. 2025-04-10]. Dostupné z: <https://doi.org/10.22489/CinC.2017.205-286>
- [18] KAUSHIK, Geetika, Pramod GAUR, Rishi Raj SHARMA a Ram Bilas PACHORI. EEG signal based seizure detection focused on Hjorth parameters from tunable-Q wavelet sub-bands. *Biomedical Signal Processing and Control* [online]. 2022, 76 [cit. 2024-04-20]. ISSN 1746-8094. Dostupné z: <https://doi.org/10.1016/j.bspc.2022.103645>
- [19] MOUREK, Jindřich. *Fyziologie: učebnice pro studenty zdravotnických oborů*. 2. dopl. vydání Praha: Grada. Sestra (Grada), 2012. ISBN 978-80-247-3918-2
- [20] SOUČEK, Miroslav, Petr SVAČINA a kolektiv. *Vnitřní lékařství v kostce*. Praha: Grada Publishing, 2019. ISBN 978-80-271-2289-9.
- [21] GONZAGA, Luana Almeida, Luiz Carlos Marques VANDERLEI, Rayana Loch GOMES a Vitor Engrácia VALENTI. Caffeine affects autonomic control of heart rate and blood pressure recovery after aerobic exercise in young adults: a crossover study. *Scientific Reports* [online]. 2017, 7(1) [cit. 2024-05-15]. ISSN 2045-2322. Dostupné z: <https://doi.org/10.1038/s41598-017-14540-4>
- [22] PARK, Junyung, Hyeon Seok SEOK, Sang-Su KIM a Hangsik SHIN. Photoplethysmogram Analysis and Applications: An Integrative Review. *Frontiers in Physiology* [online]. 2022-03-01, 12 [cit. 2022-12-18]. ISSN 1664-042X. Dostupné z: <https://doi.org/10.3389/fphys.2021.808451>
- [23] POVEA, Camilo E. a Arturo CABRERA. Practical usefulness of heart rate monitoring in physical exercise. *Revista Colombiana de Cardiología* [online]. 2018, 25(3), e9-e13 [cit. 2024-05-15]. ISSN 01205633. Dostupné z: <https://doi.org/10.1016/j.rccar.2018.05.004>
- [24] ÚŘAD PRO TECHNICKOU NORMALIZACI, METROLOGII A STÁTNÍ ZKUŠEBNICTVÍ. ČSN ISO 690:2022 (01 0197), *Informace a dokumentace – Pravidla pro bibliografické odkazy a citace informačních zdrojů*. Čtvrté vydání. Praha, 2022.

- [25] ÚŘAD PRO TECHNICKOU NORMALIZACI, METROLOGII A STÁTNÍ ZKUŠEBNICTVÍ. ČSN ISO 7144 (010161), *Dokumentace – Formální úprava disertací a podobných dokumentů*. Praha, 1997.
- [26] ÚŘAD PRO TECHNICKOU NORMALIZACI, METROLOGII A STÁTNÍ ZKUŠEBNICTVÍ. ČSN ISO 31-11, *Veličiny a jednotky – část 11: Matematické znaky a značky používané ve fyzikálních vědách a v technice*. Praha, 1999.
- [27] FARKAŠOVÁ, B.; GARAMSZEGI T.; JANSOVÁ L.; KONEČNÝ L.; KRČÁL M. et al. *Výklad normy ČSN ISO 690:2022 (01 0197) účinné od 1. 12. 2022*. Online. První vydání. 2023. Dostupné z: <https://www.citace.com/Vyklad-CSN-ISO-690-2022.pdf>. [cit. 2023-09-27].

# Seznam symbolů a zkratek

<b>VUT</b>	Vysoké učení technické v Brně
<b>CESA</b>	Centrum sportovních aktivit
<b>FEKT</b>	Fakulta elektrotechniky a komunikačních technologií
<b>BUT PPG</b>	Brno University of Technology Smartphone PPG Database
<b>WFDB</b>	WaveForm Database
<b>PPG</b>	Fotopletysmograf
<b>EKG</b>	Elektrokardiogram
<b>EEG</b>	Elektroencefalogram
<b>ACC</b>	Akcelerometr
<b>TF</b>	Tepová frekvence
<b>MTF</b>	Maximální tepová frekvence
<b>IBI</b>	Tepový interval
<b>LED</b>	Elektroluminiscenční dioda
<b>DC</b>	Stejnostměrná složka
<b>MA</b>	klouzavý průměr
$MA_{peak}$	klouzavý průměr pro zvýraznění vrcholu
$MA_{beat}$	klouzavý průměr pro zvýraznění tepu
$THR_1$	práh 1
$THR_2$	práh 2
<b>FFT</b>	Rychlá Fourierova transformace
<b>RF</b>	Náhodný les
$H_0$	Aktivita
$H_1$	Mobilita
$H_2$	Komplexita

<b>SPI</b>	Index spektrální čistoty
<b>TN</b>	Pravdivě negativní
<b>TP</b>	Pravdivě pozitivní
<b>FN</b>	Falešně negativní
<b>FP</b>	Falešně pozitivní
<b>PPV</b>	Pozitivní prediktivní hodnota
<b>Se</b>	Citlivost
<b>F1</b>	F1 skóre
<b>ME</b>	Průměrná chyba
<b>MAE</b>	Průměrná absolutní chyba
<b>RMSE</b>	Průměrná kvadratická chyba
<b>SD</b>	Standardní odchylka
<b>var</b>	rozptyl
<b>Hz</b>	Hertz
<b>ms</b>	Milisekunda
<b>s</b>	Sekunda
<b>bpm</b>	Tepy za minutu